Autor: Herbert Grosser

Trendanalyse

Das Statistische Amt der Stadt München veröffentlicht für ausgewählte Themengebiete langfristige Zeitreihen in der Internet-Anwendung „Trends und Kennzahlen“ unter der URL http://www.mstatistik-muenchen.de/datamon/

Diese Anwendung bietet eine tabellarische Übersicht über die Monatswerte des aktuellen Jahres und des Vorjahres. Außerdem bereitet sie online die letzten 24 Monatswerte oder auf Anwenderwunsch auch weiter zurückreichenden Zahlen bis zum Jahr 2000 grafisch auf. Diese Grafiken enthalten neben der Kurve mit den tatsächlich beobachteten Werten (rote Kurve) auch eine blaue Trendkurve, deren Werte mit einem in der Web-Anwendung implementierten Algorithmus berechnet werden. Die theoretischen Grundlagen für diesen Algorithmus und eine kurze Übersicht über die möglichen Berechnungsverfahren sollen in diesem Beitrag dargestellt werden.

Das traditionelle Zeitreihen-Komponentenmodell

Traditionell geht man bei unterjährigen Daten (Quartalsdaten oder Monatsdaten) von einem additiven Zeitreihenmodell aus, das sich aus vier Komponenten zusammensetzt. Die beobachteten Werte y_i werden in mathematischer Schreibweise wie folgt dargestellt:

$$y_t = T_t + Z_t + S_t + U_t \quad (\text{für } t = 1, 2, ..., N)$$

Die Einzelkomponenten haben folgende Bedeutung:

Trendkomponente T_t : Sie ist durch langfristig wirkende Ursachen bedingt (Beispiele: Veränderung des Lebensstandards, technischer Fortschritt, Veränderung der Infrastruktur usw.) und gewöhnlich eine lineare Funktion von t, solange nicht ein Zeitraum von mehreren Jahrzehnten betrachtet wird.

Zyklische Komponente Z_t: Ihr Verlauf ist durch die Konjunkturzyklen bedingt und infolge dessen üblicherweise eine wellenförmige Funktion.

Saisonkomponente S_t: Ihr Verlauf ist ebenfalls wellenförmig und durch den jahreszeitlichen Wechsel bedingt.

Irreguläre Komponente U_t: Hierunter fallen Ausreißer und Strukturbrüche, die durch historische Ereignisse erklärt werden können, sowie Zufallsschwankungen, deren Ursachen im einzelnen nicht identifiziert werden können.

Die genannten Komponenten sind imaginär, also nicht direkt beobachtbar. Sie entspringen vielmehr der menschlichen Intuition. Sie können sich durchaus auch gegenseitig beeinflussen, d.h. sie sind nicht notwendigerweise im statistischen Sinn voneinander unabhängig.

Häufig werden die Komponenten T_t und Z_t nicht getrennt betrachtet, sondern zur sogenannten **glatten Komponente G_t** zusammengefasst, weil eine Trennung dieser beiden Komponenten mit traditionellen zeitreihenanalytischen Werkzeugen problematisch ist.

Im folgenden sollen einfache Methoden zur Trendermittlung, bzw. zur Bestimmung der glatten Komponente behandelt werden. Weiterführende Informationen können verschiedenen Fachbüchern zur Zeitreihenanalyse (siehe Literaturhinweis; Seite 30) entnommen werden.

Gleitende Durchschnitte der Ordnung n als Methode der Trendbestimmung

Es kann nicht immer davon ausgegangen werden, dass die Trendkomponente einer Zeitreihe funktional ist, d. h. die beobachteten Werte in einer linearen oder nichtlinearen Beziehung dargestellt werden können.
Für diesen Fall bietet sich die Methode der gleitenden Durchschnitte an.
Die Voraussetzung für diese Methode ist lediglich die Annahme, dass die Schwankungen der Zeitreihe zyklisch verlaufen und die beobachteten Werte äquidistant sind. Das Ergebnis dieses Verfahrens ist eine Glättung der Zeitreihe: die Unregelmäßigkeiten im Kurvenverlauf, die üblicherweise bei einer Zeitreihe auftreten, werden quasi abgeschliffen.

Der gleitende Durchschnitt (GD, im amerikanischen mit MA bezeichnet) ist eine Folge von arithmetischen Mitteln, die aus beobachteten Werten von y_t gebildet werden. Er wird aus einer gleichbleibenden Anzahl zeitlich benachbarter Beobachtungswerte berechnet und dem in der Mitte des jeweiligen Zeitintervalls liegenden Zeitpunkt *t* zugeordnet. Das Zeitintervall – die Ordnung des gleitenden Durchschnitts – kann theoretisch beliebig gewählt werden. Um gut angenäherte Werte zu erhalten, die auch einer intuitiven Überprüfung standhalten, ist allerdings darauf zu achten, dass es mit dem tatsächlichem im allgemeinen aber unbekannten Zyklus übereinstimmt. Während bei jahreszeitlichen Schwankungen üblicherweise die Ordnung 12 gewählt wird, ist es bei Zeitreihen ohne saisonale Schwankungen dem subjektiven Empfinden des Statistikers überlassen, die Ordnung des Gleitenden Durchschnitts zu wählen.

Die Krümmungen der „glatten Komponente" werden um so stärker abgeschliffen, je höher die Ordnung des gleitenden Durchschnitts ist.
Bei zu kleiner Ordnung kann es also vorkommen, dass die Trendkurve einen sehr unruhigen Verlauf zeigt, während bei zu hoher Ordnung Trends unerkannt bleiben.

Ist man an einem sehr glatten Kurvenverlauf interessiert, so kann der Glättungseffekt verstärkt werden, indem man mehrere Glättungsverfahren übereinander schachtelt, d. h. nacheinander ausführt.

Beispiel:

Zeit	Wert	GD der Ordnung 3	GD der Ordnung 5
Januar	95		
Februar	94	95,0	
März	96	94,3	94,0
April	93	93,7	93,0
Mai	92	91,7	92,0
Juni	90	90,3	91,0
Juli	89	90,0	90,8
August	91	90,7	91,2
September	92	92,3	91,4
Oktober	94	92,3	92,6
November	91	93,3	92,6
Dezember	95	92,3	91,6

Die Werte der gleitenden Durchschnitte werden dem mittleren Beobachtungswert der jeweiligen Durchschnittsgruppe zugerechnet. Wie man sieht, können mit dieser Methode am Anfang und am Ende der gegebenen Zeitreihe keine Trendwerte bestimmt werden. Deshalb eignet sich die Methode auch nicht dazu, Trendprognosen durchzuführen.

Bei Wahl eines relativ kleinen Mittelungsintervalls (kleine Ordnung) werden mit Hilfe des gleitenden Durchschnitts also nur die fluktuierenden Restkomponenten der Zeitreihe abgespaltet, übrig bleiben T + K + S. Wählt man als Mittelungsintervall genau die Periode der saisonalen Komponente (also z. B. 12 Monate), wird diese ebenfalls „weggemittelt" und man erhält direkt die glatte Komponente G =T + K.

Für die Beurteilung des Verfahrens im praktischen Einsatz kann also festgehalten werden, dass der Gleitende Durchschnitt durchaus sehr effektiv ist und anschaulich und leicht nachvollziehbar zu plausiblen Ergebnissen führt. Gegenüber anderen Strategien hat dieses Verfahren wie erwähnt auch den Vorteil, dass keine a-priori Annahmen über die Form des Trendverlaufs notwendig sind. Es ist daher im allgemeinen universeller als andere Methoden, die unter Umständen von mehreren Voraussetzungen und Annahmen abhängen.

Ein gravierender Nachteil ist allerdings, dass für die ersten und letzten Glieder keine Berechnungen möglich sind. In der ersten Version der Webanwendung „Trends und Kennzahlen" des Statistischen Amtes der Stadt München, das abhängig von der betrachteten Zeitreihe entweder den gleitenden Durchschnitt der Ordnung 5 (wenn keine jahreszeitliche Komponente erkennbar ist) oder den gleitenden Durchschnitt der Ordnung 12 verwendet (wenn eine jahreszeitliche Komponente erkennbar ist), habe ich deshalb das Verfahren für die ersten und letzten Zeitreihenglieder modifiziert, damit auch eine Berechnung dieser Glieder möglich ist.

Methode der kleinsten Quadrate

Kann die glatte Komponente einer Zeitreihe annähernd mit Hilfe einer mathematischen Funktion bestimmten Typs (lineare-, Exponential-, Potenzfunktion usw.) beschrieben werden, können die zugehörigen Parameter nach der Methode der kleinsten Quadrate (englisch: Least Squares Method) bestimmt werden. Der Regressand (die abhängige Variable) ist die Variable Y mit den Beobachtungen yt und an die Stelle der unabhängigen Variable X tritt bei der Trendfunktion die Zeit t = 1,2,.....T. Es wird lediglich vorausgesetzt, dass die Reihenwerte metrisch sind.

Mathematisch gesehen ergibt sich also folgende Problemstellung: Gesucht ist eine mathematische Kurve, die derart in eine „Punktwolke" aus Daten gelegt werden kann, dass die Summe der quadrierten vertikalen Abstände zwischen den beobachteten Werten und der Regressionskurve ein Minimum ergeben. Welche Kurvenart (lineare Funktion, Polynom, Exponentialfunktion...) den tatsächlichen Verhältnissen am nächsten kommt, unterliegt der subjektiven Einschätzung des Statistikers. Die Parameter der Kurve dagegen werden streng deterministisch mit Hilfe von mathematischen Algorithmen ermittelt.

Die Zusammenhänge zwischen Regressand und Zeit müssen nicht unbedingt linear sein. Allein durch Variablensubstitution oder Variablentransformation (z. B. Logarithmustransformation) können nicht lineare Zusammenhänge mathematisch „linearisiert" werden. So können z. B. logarithmische oder exponentielle Abhängigkeiten durch geeignete Umformungen quasi wie lineare behandelt werden, auch wenn die Trendfunktion die Form einer Logarithmusfunktion oder einer Exponentialfunktion oder einer Potenzfunktion hat.

Nähere Informationen zur Gaussschen Fehlerquadratmethode, die auch unter dem Begriff Ausgleichsrechnung bekannt ist, können verschiedenen Lehrbüchern der „Numerischen Mathematik" entnommen werden.

Exponentielle Glättung

Lässt eine Zeitreihe keinerlei systematische Muster wie linearen Anstieg oder Ähnliches erkennen, kann auch mit dem Verfahren der exponentiellen Glättung die glatte Komponente ermittelt werden. Damit erhält man sogar eine Prognose für den Zeitpunkt T+1.

Das einfache exponentielle Glätten, single exponential smoothing (SES), ist ein gewichteter gleitender Durchschnitt mit geometrisch fallenden Gewichten und nur einem Parameter 0≤α≤1 (Glättungsfaktor).

Man geht von dem Ansatz aus, dass der gegenwärtige Zeitreihenwert immer auch von den vergangenen Werten beeinflusst wird, wobei sich der Einfluss abschwächt, je weiter der Wert in der Vergangenheit liegt. Durch die Gewichtung der beobachteten Zeitreihenwerte mit einem Glättungsfaktor werden starke Ausschläge auf der geschätzten Zeitreihenkurve gleichmäßig verteilt.

Formales Modell:
Sei $y_1, y_2, \ldots y_T$ die bekannte Zeitreihe. Im Zeitpunk t wird für y_t ein exponentiell geglätteter Schätzwert $\hat{y}_t$ errechnet, der sich als gewichteter Durchschnitt ergibt aus dem aktuellen Zahlenwert y_t und dem Schätzwert der Vorperiode $\hat{y}_{t-1}$ Die Gewichtung wird durch den Glättungsfaktor 0<α<1 bestimmt.
Man erhält:

$$\hat{y}_t = \alpha \cdot y_t + (1-\alpha) \cdot \hat{y}_{t-1}$$

Die geschätzte Zeitreihe baut sich so rekursiv auf. Der Startwert $\hat{y}_0$ kann für die praktische Ermittlung beliebig gewählt werden. Baut man nun beginnend von $\hat{y}_0$ die geglättete Zeitreihe auf

$$\begin{aligned}
\hat{y}_1 &= \alpha \cdot y_1 + (1-\alpha) \cdot \hat{y}_0, \\
\hat{y}_2 &= \alpha \cdot y_2 + (1-\alpha) \cdot \hat{y}_1, \\
\hat{y}_3 &= \alpha \cdot y_3 + (1-\alpha) \cdot \hat{y}_2, \\
&\ldots.
\end{aligned}$$

so erhält man, wenn man die Rekursivität auflöst

$$\hat{y}_t = \alpha \cdot y_t + \alpha \cdot (1-\alpha)\, y_{t-1} + \alpha \cdot (1-\alpha)^2 y_{t-2} + \ldots + \alpha \cdot (1-\alpha)^{t-1} y_1 + \alpha \cdot (1-\alpha)^t y_0$$

Der Schätzwert $\hat{y}_t$ liefert den Prognosewert für den Zeitpunkt t+1. Wie man erkennt, ist der Einfluss der weiter zurückliegenden Beobachtungswerte bei der Schätzung des momentanen Werts von α abhängig. . Wegen $0 < \alpha < 1$ liegt der Wert $1 - \alpha$ ebenfalls zwischen 0 und 1. Die Folge $(1-\alpha)^n$ ist damit streng monoton fallend, so dass gilt: je kleiner α um so kleiner ist der Einfluss der weiter zurück liegenden Werte.

Für die Wahl des Glättungsfaktors wird häufig 0,2 bis 0,3 empfohlen. Man kann auch mit Hilfe der Regressionsanalyse den Glättungsfaktor schätzen.

Die genannten Verfahren sind keineswegs die einzigen, die zur Schätzung der glatten Komponente verwendet werden können. Weitere Verfahren sind z. B. die Spline-Interpolation und die Differenzenbildung, um nur die wichtigsten zu nennen.

Vor allem das Statistik-Paket SPSS stellt in einem Zusatztool SPSS-Trends zahlreiche Methoden der modernen Zeitreihenanalyse bereit. Unter anderem wird auch ein spektralanalytisches Verfahren angeboten, ein Verfahren aus der Nachrichtentechnik, das durch Überlagerung trigonometrischer Schwingungskomponenten mit verschiedenen Grundfrequenzen die Zeitreihe annähert. Der klassische Ansatz des „Zeitreihen-Komponentenmodells“ wird hier aufgegeben.

Die theoretischen Begründungen für den spektralanalytischen Ansatz basieren auf den hochkomplexen mathematischen Überlegungen der „Fourier-Reihen“ und „Laplace-Transformation“.

Berliner Verfahren

Das Berliner Verfahren basiert dagegen ebenfalls auf dem traditionellen Komponentenmodell. Die mathematischen Grundlagen dieses Verfahrens wurden in den sechziger Jahren an der Technischen Universität in Berlin (daher der Name) und im Deutschen Institut zur Wirtschaftsforschung entwickelt. Seit 1983 ist im Statistischen Bundesamt die Vierte Verfahrensversion (BV4.1) – eine eigenständige Weiterentwicklung durch das Statistische Bundesamt – im Einsatz. Sie unterscheidet sich durch methodische Verbesserungen bei der Behandlung von Kalendereffekten und von so genannten Ausreißern.

Für den Trend-Konjunktur-Prozess wird angenommen, dass es sich um einen nichtdeterministischen Prozess handelt (solche Vorgänge sind dadurch gekennzeichnet, dass es sich nicht um vollständig bekannte und daher auch nicht um jederzeit exakt prognostizierbare Wirkungsmechanismen handelt), der sich durch Polynome niedriger Ordnung hinreichend genau approximieren lässt. Für die Saison-Komponente wird angenommen, dass er schwach stationär ist (Erwartungswert und Varianz der Beobachtungen sind zeitinvariant) und hinreichend genau durch eine endliche Fourierreihe (Stufe 3) abgebildet werden kann.

Es ergibt sich somit das folgende Basismodell von BV4.1

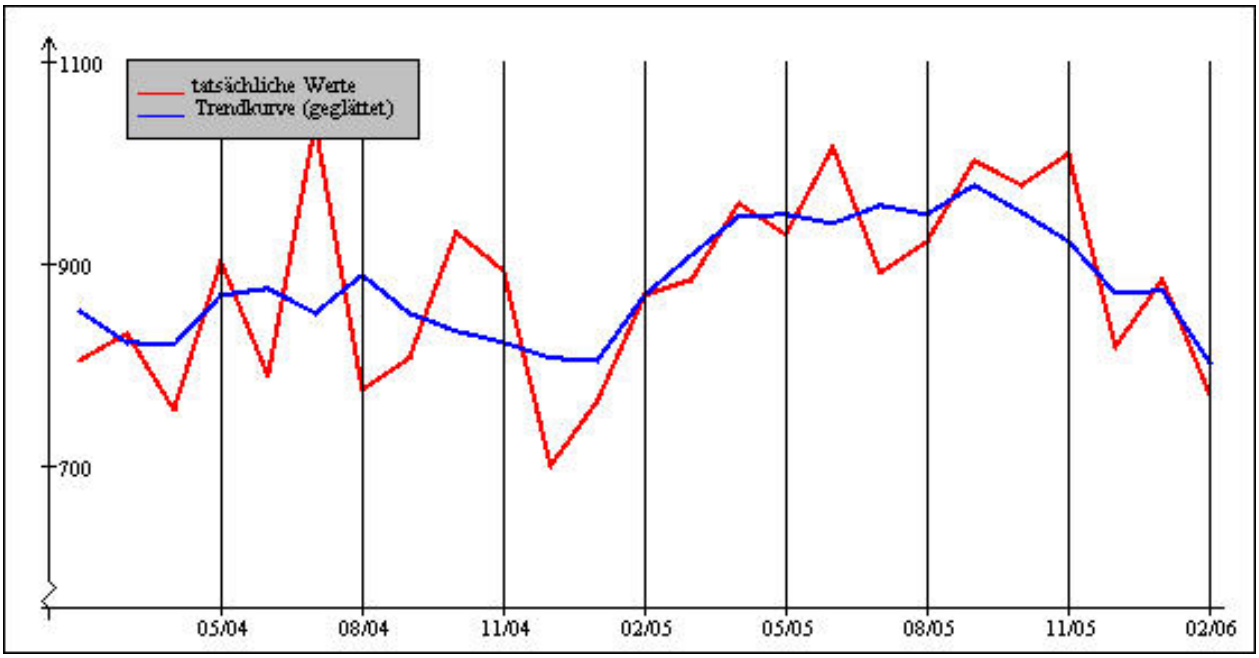
$$\hat{x}_t = \sum_{j=0}^{3} a_j t^j + \sum_{j=1}^{t} (\beta_i \cos \lambda_i t + \gamma_i \sin \lambda_i t)$$

Für Interessierte sei auf die nicht unbedingt leicht nach zu vollziehende Ausarbeitung des Statistischen Bundesamtes verwiesen, das im Heft 3, Jahrgang 2004 seiner Methodenberichte über die Komponentenzerlegung und Saisonbereinigung ökonomischer Zeitreihen mit dem Verfahren BV4.1, verfasst von Hans-Theo Speth, berichtet. Wie den Grafiken entnommen werden kann, ist der verwendete Algorithmus sehr effektiv und führt zu überzeugenden Lösungen.

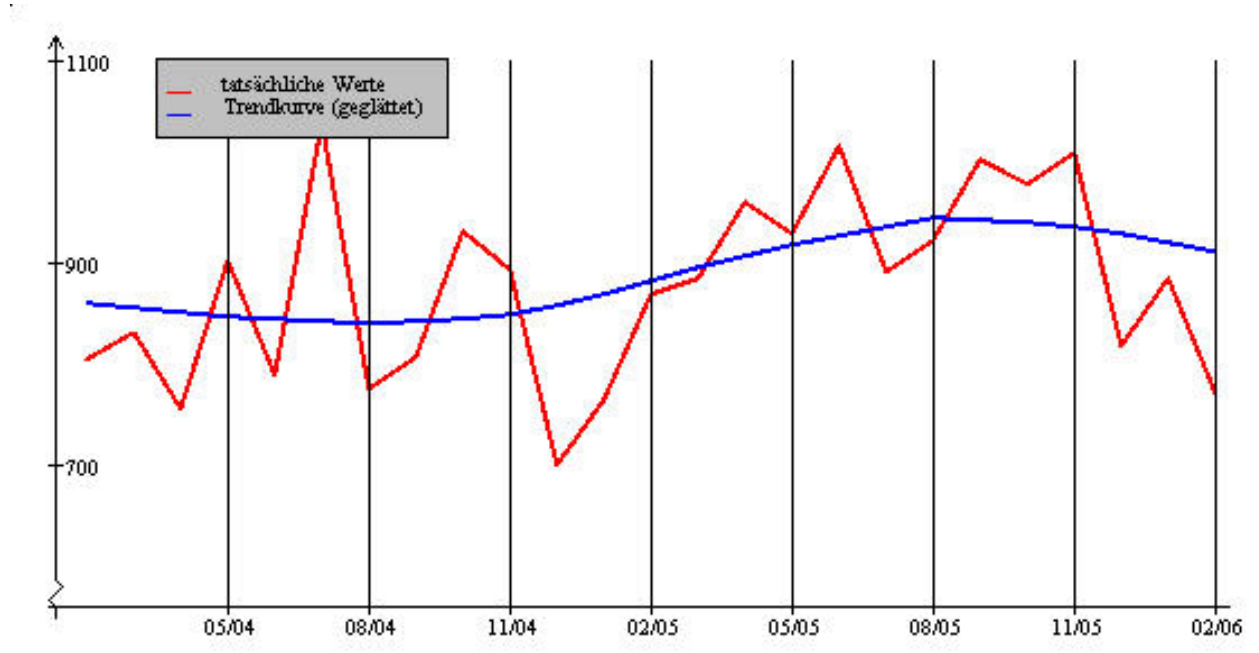
Freundlicherweise stellt allerdings das Statistische Bundesamt für nicht kommerzielle Zwecke diese Verfahren zur Verfügung. Da dieses Verfahren naturgemäß (Komplexität!) beste Ergebnisse für die Trendanalyse ermittelt, habe ich mich dazu entschlossen, diese Verfahren auch bei der grafischen Darstellung der Monatswerte im Rahmen der Web-Anwendung „Trends und Kennzahlen“ des Statistischen Amtes der Stadt München zum Einsatz zu bringen.

Im Nachfolgenden soll an ausgewählten Beispielen die Effizienz dieses Verfahrens verdeutlicht werden. Zu jeder Zeitreihe, deren Trendkurve mit Hilfe der gleitenden Durchschnitte berechnet wurde, gibt es ein Pendant zum Berliner Verfahren. Der interessierte Leser wird von sich aus die Vorzüge dieses Verfahrens erkennen.

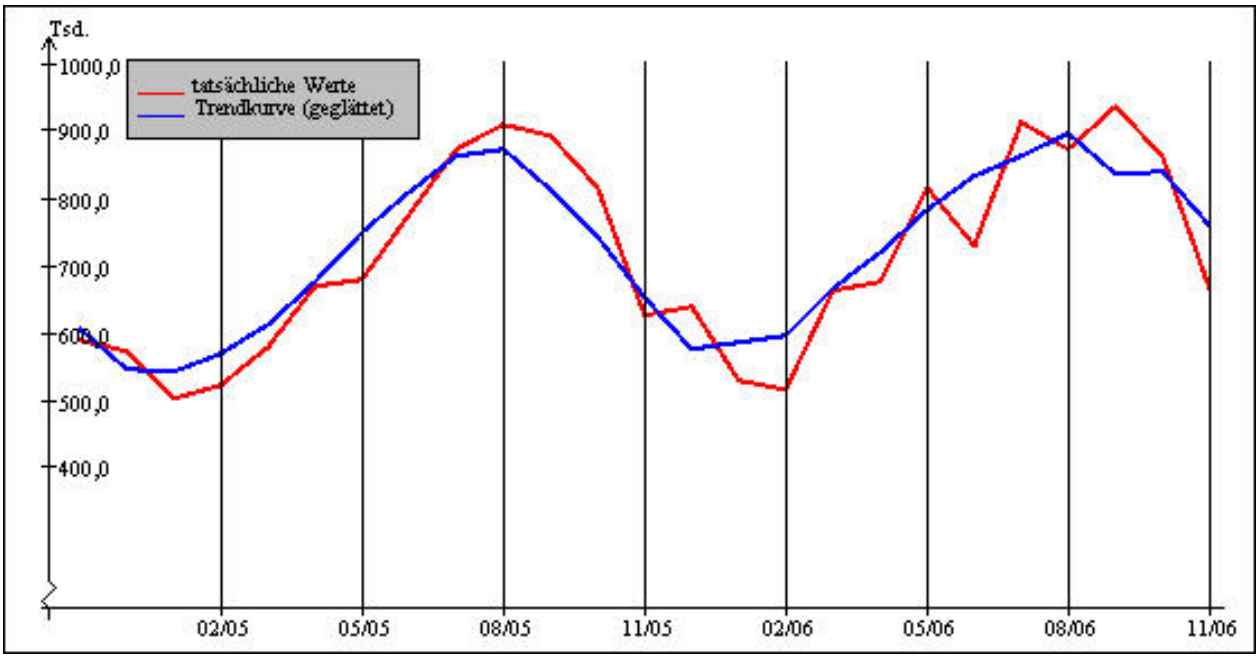
Geburten Deutsche (blaue Kurve berechnet mit dem Verfahren der Gleitenden Durchschnitte der Ordnung 5)



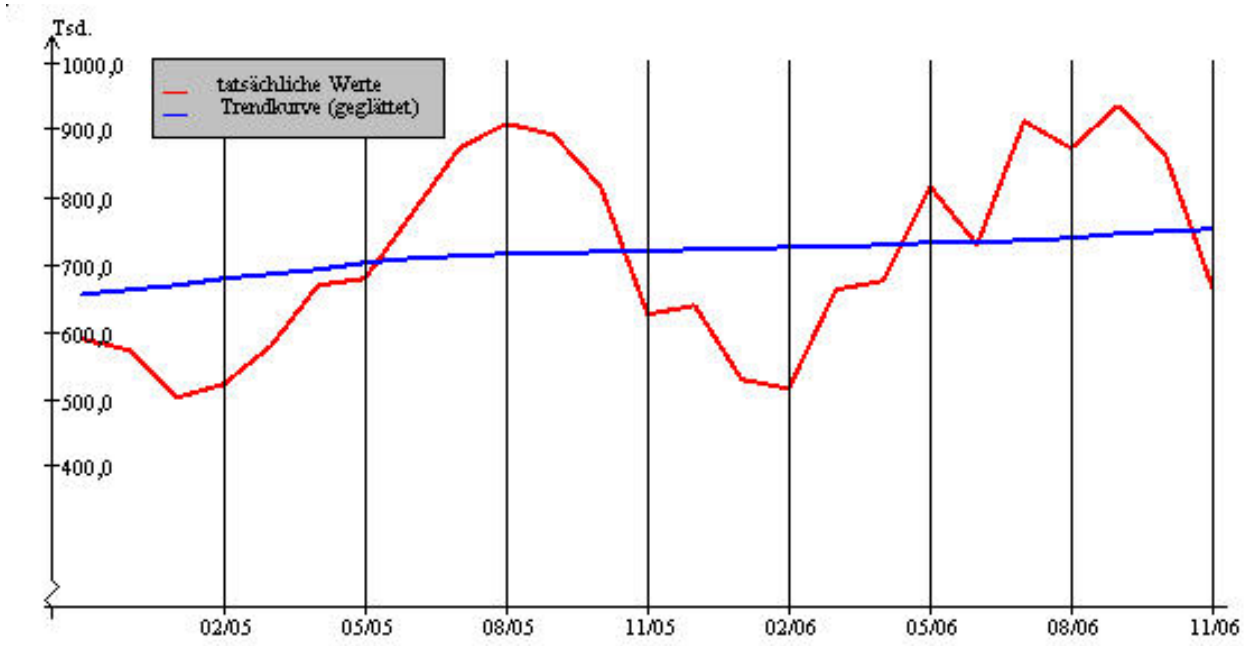
Geburten Deutsche (blaue Kurve berechnet mit dem Berliner Verfahren 4.1)



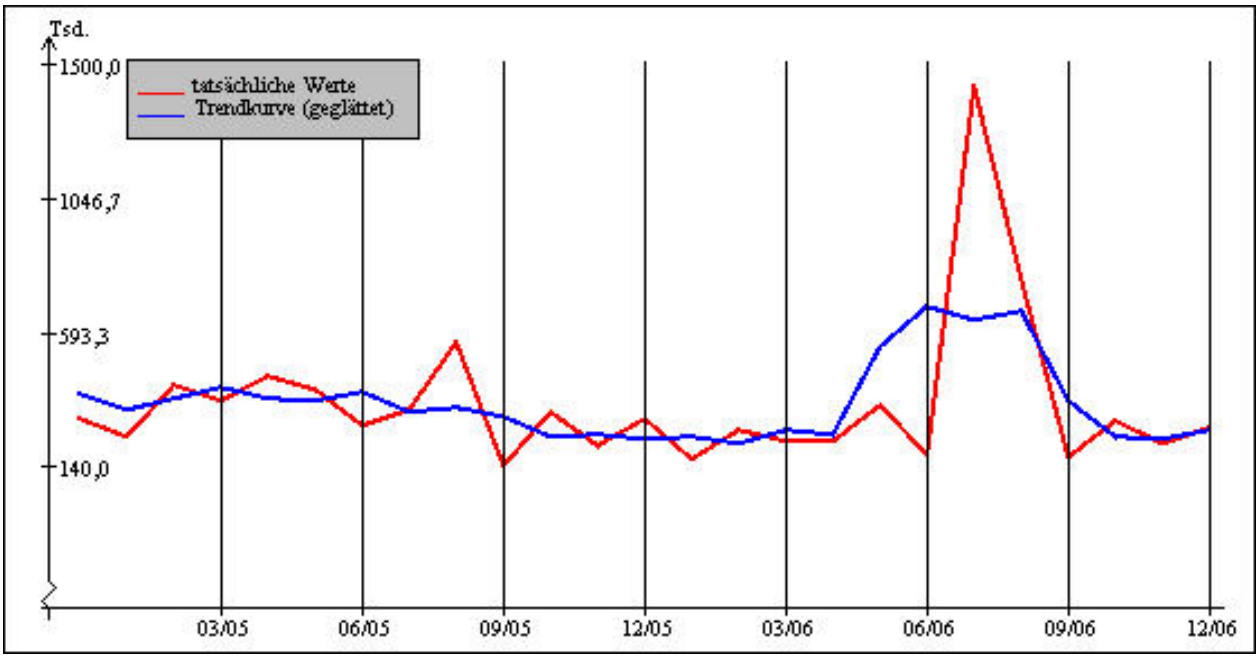
Übernachtungen insgesamt (blaue Kurve berechnet mit dem Verfahren der Gleitenden Durchschnitte der Ordnung 5)



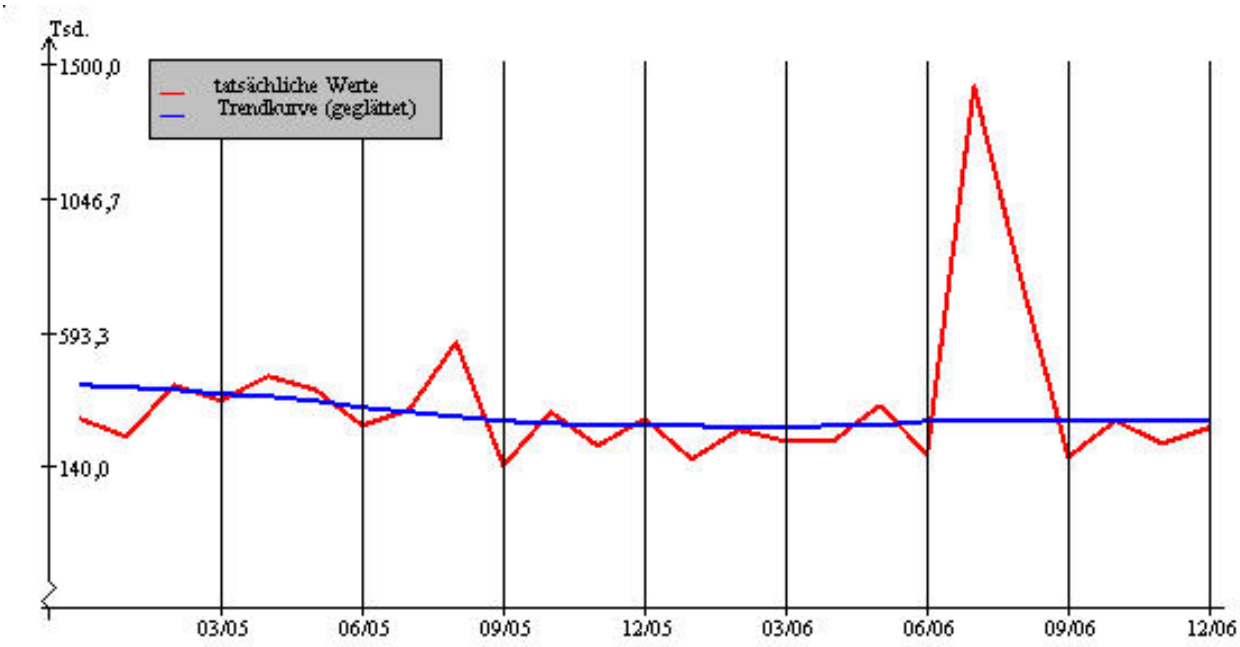
Übernachtungen insgesamt (blaue Kurve berechnet mit dem Berliner Verfahren 4.1)



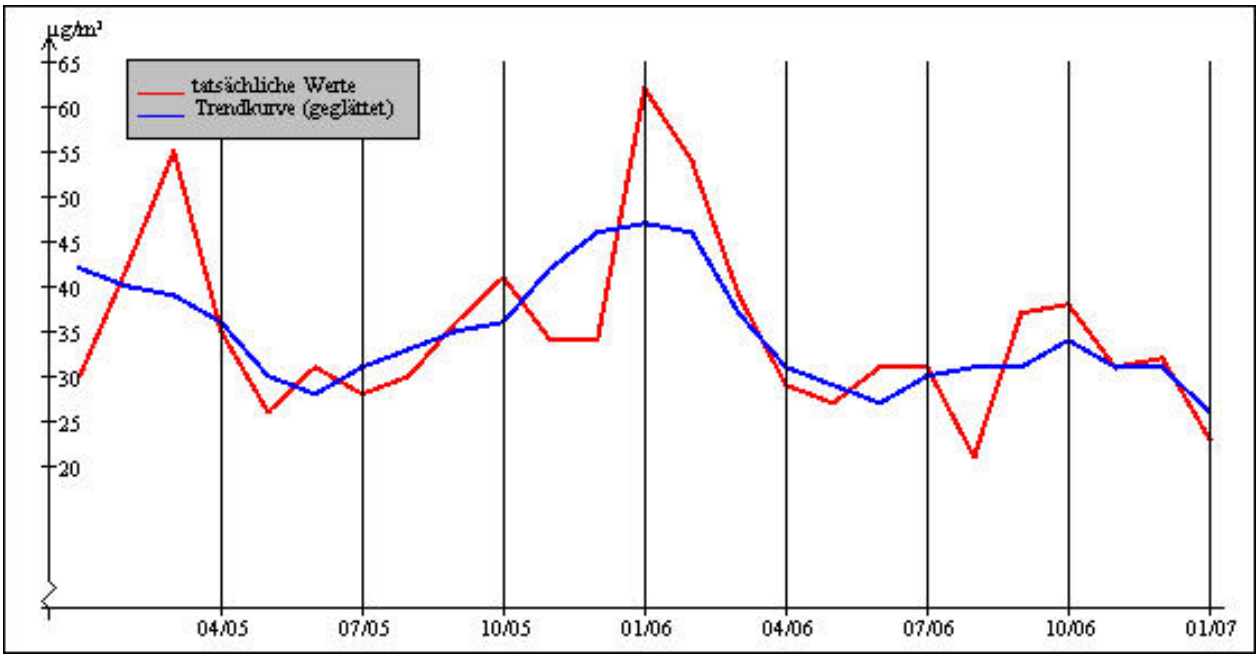
Besucher Olympiapark (blaue Kurve berechnet mit dem Verfahren der Gleitenden Durchschnitte der Ordnung 5)



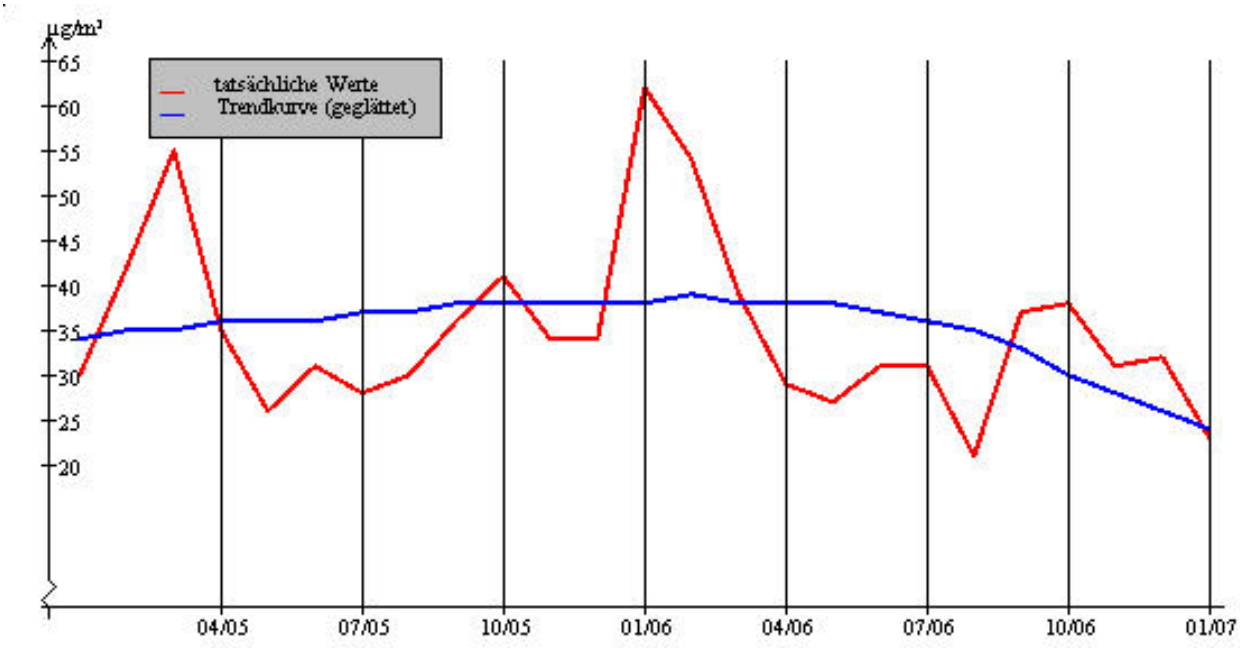
Besucher Olympiapark (blaue Kurve berechnet mit dem Berliner Verfahren 4.1)



Feinstaub (blaue Kurve berechnet mit dem Verfahren der Gleitenden Durchschnitte der Ordnung 5)



Feinstaub (blaue Kurve berechnet mit dem Berliner Verfahren 4.1)



Literatur

Bamberg/Baur(1980): Statistik, Oldenbourg Verlag.

Bronstein, Semendjajew, Musiol, Mühlig (2006) Taschenbuch der Mathematik, Verlag Harri Deutsch.

Höpfner, B. (1998): *Ein empirischer Vergleich neuerer Verfahren zur Saisonbereinigung und Komponentenzerlegung*, in: Wirtschaft und Statistik, Heft 12/1998, S. 949-959, Statistisches Bundesamt, Wiesbaden.

Lovell, M. C. (1963): *Seasonal adjustment of economic time series and multiple regression analysis*, in: American
Statistical Association Journal, Dezember 1963, S. 993-1010.

Nourney, M. (1983): *Umstellung der Zeitreihenanalyse*, in: Wirtschaft und Statistik, Heft 11/1983, S. 841-852, Statistisches Bundesamt, Wiesbaden.

Nullau, B., Heiler, S. u.a. (1969): *Das „Berliner Verfahren" – Ein Beitrag zur Zeitreihenanalyse*, DIW-Beiträge zur Strukturforschung, Heft 7, Berlin.

Speth(2004), Heft 3 Mothodenberichte des Statistischen Bundesamts in: Komponentenzerlegung und Saisonbereinigung ökonomischer Zeitreihen mit dem Verfahren BV4.1.

Voß (2004) Taschenbuch der Statistik, Fachbuchverlag Leipzig.