Eine robuste, datengesteuerte Version des Berliner Verfahrens

In Heft 9/2000 dieser Zeitschrift wurde mit dem Beitrag „Selektive soziale Interaktion" von Dr. Heike Wirth die erste im Rahmen des Gerhard-Fürst-Preises mit einem Förderpreis für wissenschaftliche Nachwuchskräfte prämierte Dissertation ausführlich dargestellt.

Es folgt nun der Beitrag von Herrn Dr. Yuanhua Feng, wissenschaftlicher Mitarbeiter im Zentrum für Finanzen und Ökonometrie der Universität Konstanz, und seinem Doktorvater, Herrn Professor Dr. Siegfried Heiler. Fengs zugrunde liegende Dissertation „Kernel and Locally Weighted Regression with Application to Time Series Decomposition" beinhaltet Ansätze zur Weiterentwicklung des in der amtlichen Statistik seit 1983 zur Saisonbereinigung und Komponentenzerlegung von Zeitreihen eingesetzten Verfahrens BV4 hin zu einem Verfahren mit datengesteuerter Wahl der Verfahrensparameter.

Einleitung

Die Zerlegung saisonaler Zeitreihen in unbeobachtbare Trend-Zyklus- und saisonale Komponenten hat eine lange Tradition. Sie stellt ein sehr wichtiges Problem der Ökonometrie dar und liefert bereinigte Daten für eine prospektive Analyse (z. B. für eine laufende Konjunkturanalyse). Für diesen Zweck existiert eine große Anzahl unterschiedlicher methodischer Ansätze und auch ausgearbeiteter Softwarepakete.[1]) Heiler hat ein Zerlegungsverfahren auf Grundlage lokaler Regression mit Polynomen und trigonometrischen Funktionen als lokale Regressoren entwickelt.[2]) Aus dieser Idee entstand schließlich das sogenannte Berliner Verfahren (BV), welches in seiner vierten Version (BV 4) vom Statistischen Bundesamt seit 1983 verwendet wird. Vergleiche zwischen unterschiedlichen Ansätzen zur Zeitreihenzerlegung, eingeschlossen das BV 4 mit empirischen makroökonomischen Daten, sind vom Statistischen Bundesamt durchgeführt worden.[3])

Die traditionelle Idee der lokalen Regression wurde von Stone[4]) und Cleveland[5]) zu einer sogenannten lokal gewichteten Regression (LWR) verallgemeinert, die sich zum vielversprechendsten nichtparametrischen Regressionsansatz in den letzten Jahren entwickelt hat.[6]) Dieser Ansatz in Verbindung mit den neuen Entwicklungen auf dem Gebiet der nichtparametrischen Statistik und dem Gebiet der Informatik seit den 80er Jahren erlaubt es uns, eine neuartige Version des BV vorzustellen. Heiler und Michels verallgemeinerten das auf der LWR basierende BV, indem sie einen Kern als Gewichtsfunktion einführten.[7]) Wie bei anderen nichtparametrischen Ansätzen verlangt die sinnvolle Anwendung der neuen BV-Variante die Auswahl einiger Glätteparameter, wie zum Beispiel die Ordnung des Polynoms und die Bandbreite. Daher ist die Entwicklung datengesteuerter Verfahren zur Durchführung des neuen Verfahrens ein entscheidendes theoretisches und praktisches Problem. Die erste datengesteuerte Version des BV wurde von Heiler und Feng[8]) entwickelt. Bei diesem Verfahren werden Techniken zur Behandlung von Ausreißern in den Daten nicht berücksichtigt.

Jedoch ist die lokal gewichtete Regression anfällig für Ausreißer innerhalb des Datensatzes, da zu einem Zeitpunkt t nur ein Teil der Beobachtungen für die lokale Glättung verwendet wird. Der Vorschlag von Cleveland[9]) ist ein robuster Ansatz, der bei allgemeinen, nichtparametrischen Regressionen gut funktioniert. In dieser Arbeit ändern wir zunächst Clevelands Idee der Zerlegung von saisonalen Zeitreihen mit gegebenen Glätteparametern in geeigneter Weise ab. Dann entwickeln wir ein robustes, datengesteuertes Verfahren zur Zerlegung von Zeitreihen, indem wir die einfache Doppelglättungsregel (Double Smoothing procedure – DS) für die Auswahl der Bandbreite[10]) und das Bayesische Informations-Kriterium (BIC) für die Auswahl der Ordnung des Polynoms[11]) verwenden. Das vorgeschlagene, robuste datengesteuerte Verfahren wird auf einige makro-ökonomische Zeitreihen angewandt, welche in den neuesten vom Statistischen Bundesamt durchgeführten Studien verwendet wurden, um so dessen Nützlichkeit in der Praxis zu zeigen.

---

[1]) Für einen Überblick über die Methoden auf diesem Gebiet seit Beginn der 60er Jahre siehe Heiler, S.: „Zur Glättung saisonaler Zeitreihen" in Rinne, H./Rüger, B./Strecker, H. (Hrsg.): „Grundlagen der Statistik und ihre Anwendungen", Festschrift für Kurt Weichselberger, Heidelberg 1995, S. 128-148. Siehe auch Statistisches Amt der Europäischen Gemeinschaften (Eurostat): "Seasonal Adjustment Methods – A Comparison", Luxembourg 1998.

[2]) Siehe Heiler, S.: „ Analyse der Struktur Wirtschaftlicher Prozesse durch Zerlegung von Zeitreihen", Dissertation, Universität Tübingen, 1966; sowie ders.: „Theoretische Grundlagen des ‚Berliner Verfahrens'" in Wetzel, W. (Hrsg.): „Neuere Entwicklungen auf dem Gebiet der Zeitreihenanalyse", Sonderheft zum Allgemeinen Statistischen Archiv, Band 1, 1970, S. 67-93.

[3]) Siehe Speth, H.-Th.: „Vergleich von Verfahren zur Komponentenzerlegung von Zeitreihen" in WiSta 2/1994, S. 98 ff. sowie Höpfner, B.: „Ein empirischer Vergleich neuerer Verfahren zur Saisonbereinigung und Komponentenzerlegung" in WiSta 12/1998, S. 949 ff.

[4]) Siehe Stone, C.J.: "Consistent nonparametric regression (with discussion)" in The Annals of Statistics, 5/1977, S. 595-620.

[5]) Siehe Cleveland, W.S.: "Robust locally weighted regression and smoothing scatterplots" in Journal of the American Statistical Association, 74/1979, S. 829-836.

[6]) Siehe die Monographie von Fan, J./Gijbels, I.: "Local Polynomial Modeling and its Applications", London 1996.

[7]) Siehe Heiler, S./Michels, P.: „Deskriptive und Explorative Datenanalyse", München 1994.

[8]) Siehe Heiler, S./Feng, Y.: „Datengesteuerte Zerlegung saisonaler Zeitreihen" in ifo Studien, 3/1996, S. 41-73, sowie dies.: "Data-driven decomposition of seasonal time series", 2000, erscheint im Journal of Statistical Planning and Inference.

[9]) Siehe Fußnote 5.

[10]) Siehe Feng, Y./Heiler, S.: "Selecting bandwidth for nonparametric regression based on double smoothing rule", Vorabdruck, Universität Konstanz, 1999.

[11]) Siehe Feng, Y.: "Kernel and Locally Weighted Regression – with applications to time series decomposition", Berlin 1999.

1 Die Schätzer

1.1 Verallgemeinerung des Berliner Verfahrens

Das BV basiert auf einem lokalen Kleinst-Quadrate-Kriterium. Im BV 4 werden lokal gewichtete Kleinst-Quadrate-Schätzer mit einer festen Gewichtsfunktion eingeführt.[12] Dieser Ansatz wird von Heiler und Michels[13] auf der Basis von LWR verallgemeinert. Die zugrunde liegende Idee ist die folgende: Es sei Y_t, $t=1, ..., n$, eine äquidistante Zeitreihe. Es wird angenommen, daß (eventuell nach einer geeigneten Transformation der Originaldaten) Y_t einem additiven Komponentenmodell folgt,

$$Y_t = G(t) + S(t) + \varepsilon_t,\ t = 1, 2, ..., n, \quad (1)$$

wobei weiter unterstellt wird, daß die ε_t unabhängig identisch verteilte Zufallsvariablen sind mit $E(\varepsilon_t) = 0$ und $\mathrm{var}(\varepsilon_t) = \sigma^2$. G ist die Trend-Zyklus-Komponente, S die saisonale Komponente mit der Saisonperiode s und $m := G + S$ ist die Mittelwertfunktion.

Es wird angenommen, daß die Trend-Zyklus-Komponente gewisse Glattheitseigenschaften hat, insbesondere, daß sie überall mindestens $(p+1)$ mal differenziert werden kann, so daß sie in der Umgebung eines Zeitpunkts t_0 in eine Taylor-Reihe entwickelt werden kann und eine lokale Polynomialdarstellung der Ordnung p liefert,

$$G(t) \doteq \sum_{j=0}^{p} \beta_{1j}(t_0)(t-t_0)^j.$$

Auf analoge Weise soll die saisonale Komponente lokal durch eine Fourier-Reihe dargestellt werden können,

$$S(t) \doteq \sum_{j=1}^{q} \left[\beta_{2j}(t_0)\cos\lambda_j(t-t_0) + \beta_{3j}(t_0)\sin\lambda_j(t-t_0\right.$$

wobei $q = [s/2]$ mit $[\chi]$ = größte ganzzahlige Zahl kleiner oder gleich χ *ist*, $\lambda_1 = 2\pi/s$ ist die saisonale Frequenz und $\lambda_j = j\lambda_1$, für $j = 2, ..., q$.

Setze

$$\beta_1(t_0) = (\beta_{10}(t_0),...,\beta_{1p}(t_0))^T,$$
$$\beta_2(t_0) = (\beta_{21}(t_0),\beta_{31}(t_0),...,\beta_{2q}(t_0),[\beta_{3q}(t_0)])^T,$$
$$\beta(t_0) = (\beta_1(t_0)^T,\beta_2(t_0)^T)^T,$$

$$x_1(t) = (1,(t-t_0),...,(t-t_0)^p)^T,$$
$$x_2(t) = (\cos\lambda_1(t-t_0),\sin\lambda_1(t-t_0),...,$$
$$\cos\lambda_q(t-t_0),[\sin\lambda_q(t-t_0)])^T,$$
$$x(t) = (x_1(t)^T, x_2(t)^T)^T,$$

so daß $X = (X_1 : X_2)$ mit den Zeilen $x(t)^T$ für die lokal gewichtete Regression die $n \times (p+s)$-Regressionsmatrix darstellt. Wenn $\lambda_q = \pi$ gilt, entfällt der letzte Sinusterm in [ ] wegen $\sin \pi(t-t_0) \equiv 0$.

K, die Gewichtungsfunktion von LWR, sei eine Kernfunktion zweiter Ordnung mit kompaktem Träger [-1,1], $h \in \mathbb{N}$ die Bandbreite und $y = (Y_1, ..., Y_n)^T$ stellt den Datenvektor dar. $K = diag(k_t)$ sei die Gewichtungsmatrix mit den Diagonalelementen

$$k_t = \begin{cases} K\left(\dfrac{t-t_0}{h+0{,}5}\right), & t \in [t_0-h, t_0+h], \\ 0 & \text{sonst} \end{cases}$$

e_j bezeichne den j-ten $(p+1) \times 1$ Einheitsvektor und Φ_s bezeichne einen $(s-1) \times 1$ Vektor mit 1 als ungerade Einträgen und 0 sonst.

Das lokal gewichtete Kleinst-Quadrate-Kriterium

$$\sum_{t=1}^{n} \left[Y_t - x_1(t)^T\beta_1(t_0) - x_2(t)^T\beta_2(t_0)\right]^2 k_t \Rightarrow \min,$$

führt zu den Lösungen

$$\hat{\beta}(t_0) = (X(t_0)^T K(t_0) X(t_0))^{-1} X(t_0)^T K(t_0) y \quad (2)$$

und

$$\hat{m}(t_0) = (e_1^T, \Phi_s^T)(X^T K X)^{-1} X^T K y =: w^T y, \quad (3)$$
$$\hat{G}(t_0) = (e_1^T, 0^T)(X^T K X)^{-1} X^T K y =: w_1^T y, \quad (4)$$

und

$$\hat{S}(t_0) = (0^T, \Phi_s^T)(X^T K X)^{-1} X^T K y =: w_2^T y, \quad (5)$$

wobei 0 einen Nullvektor entsprechender Dimension bezeichnet.

$\hat{m}$, $\hat{G}$ und $\hat{S}$ sind lineare Glätter und nur Beobachtungen mit $t \in [t_0-h, t_0+h]$ erhalten Gewichte ungleich Null. Die von Null verschiedenen Anteile von w, w_1 und w_2 werden als Gewichtungssysteme bezeichnet. Es kann leicht gezeigt werden, daß w in (3) folgenden Bedingungen genügt:

1. $w_i(t) = 0$, wenn $|i-t| > h$,
2. $\sum_{i=1}^{n} w_i(t)((i-t)/n)^j = \begin{cases} 1, & j=0, \\ 0, & 1 \le j \le p, \end{cases}$
2'. $\begin{cases} \sum_{i=1}^{n} w_i(t)\cos(\lambda_j(i-t)) = 1, \\ \sum_{i=1}^{n} w_i(t)\sin(\lambda_j(i-t)) = 0, \end{cases} \quad j = 1, ..., q \quad (6)$
3. $\tilde{w}'\tilde{K}^{-1}\tilde{w} = \min!$ bezüglich $\tilde{w}$,

wobei $\tilde{K}$ der von Null verschiedene Teil von K und $\tilde{w}$ der von Null verschiedene Teil von w ist. Die Eigenschaften 2 und 2' in (6) stellen sicher, daß die vorgeschlagenen Schätzer unverzerrt sind für eine polynomiale Trend-Zyklus-Komponente und für eine exakt periodische Saisonkomponente. Für Schätzungen zu einem anderen Zeitpunkt im Mittelbereich der Zeitreihen ($t_0 \in [h+1, n-h]$) erhalten wir dieselben Gewichtungssysteme (d. h., daß im Mittelbereich der Zeitreihe diese Prozedur wie ein gleitender Durchschnitt funktioniert).

Wie bei der lokalen Polynomialanpassung kann die ν-te Ableitung der Trend-Zyklus-Komponente, $0 < \nu \le p$ geschätzt werden durch

[12] Siehe Nourney, M.: „Umstellung der Zeitreihenanalyse" in WiSta 11/1983, S. 841 ff.
[13] Siehe Fußnote 7.

$$\hat{G}^{(\nu)}(t_0) = \nu!(e^T_{\nu+1}, 0^T)(X^TKX)^{-1}X^TKy$$
$$=: (w^\nu)^T y. \qquad (7)$$

Eigenschaften für endliche Stichproben und asymptotische Eigenschaften dieser Schätzer sind bei Feng[14]) ausführlich dargestellt.

1.2 Der Ansatz am Rand

Ein Punkt $t \in [1, h] \cup [n-h+1, n]$ wird Randpunkt genannt. An diesem Punkt sind die Beobachtungen, die in die Schätzung einbezogen werden, nicht symmetrisch in der Umgebung von t. Die Qualität der Schätzung an einem solchen Randpunkt ist daher im allgemeinen schlechter als an einem Punkt im Mittelbereich der Zeitreihe. Dies ist das sogenannte Randproblem. Um mit diesem Problem fertig zu werden, unterscheiden wir zwischen linker Bandbreite h_l und einer rechten Bandbreite h_r und setzen $h = \max(h_l, h_r)$. Es wird angenommen, daß $h_l < t$, $h_r \le n-t$ und $h_T > p+s$, wobei $h_T = h_l + h_r + 1$ als die gesamte Bandbreite bezeichnet wird. Sind h_l und h_r gegeben und ist $t \in [h_l + 1, n - h_r]$, dann arbeiten die Schätzer $\hat{m}, \hat{G}, \hat{G}^{(\nu)}$ und $\hat{S}$ als gleitende Mittelwerte mit symmetrischen Gewichtungssystemen für $h_l = h_r$ oder asymmetrischen Gewichtungssystemen für $h_l \neq h_r$. In der Veröffentlichung von Heiler und Feng[15]) können sich sowohl h_T als auch p von einem Punkt zum anderen im Randbereich ändern, um optimale Zerlegungsergebnisse zu erzielen. Jedoch sind die Schätzungen, die man bei diesem Verfahren erhält, nicht immer stabil im Randbereich. Dieses Problem wird dadurch gelöst, daß h_T und p festgelegt werden, das heißt es wird einfach eine optimale einheitliche gesamte Bandbreite $\hat{h}_T$ zusammen mit einer optimalen einheitlichen Ordnung des Polynoms $\hat{p}$ ausgewählt. In diesem Falle sind die vorgeschlagenen Schätzer k-NN Schätzer. Der Gebrauch von k-NN Schätzern zur Lösung des Randproblems wurde von Gasser und anderen[16]) vorgeschlagen.

Ein k-NN Schätzer ist ein Schätzer mit einer fixierten gesamten Bandbreite $h_T = h_l + h_r + 1$, die sowohl im Randbereich als auch im Mittelbereich gleich bleibt. Die linke Bandbreite h_l und die rechte Bandbreite h_r hängen von t ab. Hier werden nur ungerade Zahlen $h_T \in [p + s + 1, n]$ als mögliche gesamte Bandweiten betrachtet, da das Gewichtungssystem im Mittelbereich symmetrisch ist. Es sei $h_m = (h_T - 1)/2$. Dann sind die linken und rechten Bandbreiten zu jedem Zeitpunkt t bestimmt durch

$$\begin{array}{lll} h_l = t-1, & h_r = h_T - t, & \text{wenn } t \le h_m, \\ h_l = h_m, & h_r = h_m, & \text{wenn } h_m < t \le n - h_m, \\ h_l = h_T - (n-t) - 1, & h_r = n - t, & \text{sonst.} \end{array} \qquad (8)$$

Ein nicht-robustes datengesteuertes Verfahren zur Wahl von h_m und p für den k-NN Schätzer wird im nächsten Abschnitt angegeben.

[14]) Siehe Fußnote 11.
[15]) Siehe Fußnote 8.
[16]) Siehe Gasser, T./Müller, H.G./Mammitzsch, V.: "Kernels for nonparametric curve estimation" in Journal of the Royal Statistical Society, Series B, 47/1985, S. 238-252.

2 Nicht-robustes datengesteuertes Verfahren

Von hier ab werden nur die Schätzungen für m, G und S betrachtet.

Die optimale Auswahl der Parameter h_T und p minimiert ein gegebenes Fehlerkriterium als Abstandsmaß zwischen Schätzer und der (unbekannten) zugrunde liegenden Funktion. In dieser Arbeit bezeichnet m die Zielfunktion, das heißt $\hat{m}$ wird in Bezug auf m optimiert. Als Fehlerkriterium bei der Auswahl der Bandbreite benutzen wir den durchschnittlichen mittleren quadratischen Fehler (MASE)

$$M = n^{-1}\sum_{t=1}^{n} E\left[\hat{m}_t - m_t\right]^2. \qquad (9)$$

Es ist bekannt, daß der MASE sich additiv zusammensetzt aus einem Varianzteil V und einem Verzerrungsteil B, das heißt $M = V + B$. Unter der Annahme, daß ε_t unabhängig identisch verteilte (u.i.v.) Zufallsvariablen sind, ist der Varianzteil eines k-NN Schätzers gegeben wie folgt:

$$\hat{V} = \hat{\sigma}^2 n^{-1}\sum_{t=1}^{n}\sum_{i=1}^{n}\left(w_i(t)\right)^2,$$

wobei $\hat{\sigma}^2$ ein Schätzer für σ^2 ist. In dieser Arbeit wird $\hat{\sigma}^2 = \hat{\sigma}^2_B$ benutzt, wobei $\hat{\sigma}^2_B$ ein Bootstrap-Varianzschätzer ist.[17])

$\hat{\sigma}^2_B$ ist definiert durch

$$\hat{\sigma}^2_B = n^{-1}\sum_{i=1}^{n} r_i^2$$

wobei r_i's die Residuen einer datengesteuerten Pilotglättung sind.[18]) Dieser Schätzer ist genau die durchschnittliche Residuensumme der Quadrate einer Pilotschätzung. Ein einfacher Schätzer für M wird von Rice[19]) vorgeschlagen

$$\tilde{R} = n^{-1}\sum_{t=1}^{n}\left(\hat{m}_t - y_t\right)^2 + \left(n^{-1}\sum_{t=1}^{n} 2w_t(t) - 1\right)\hat{\sigma}^2. \qquad (10)$$

Diese Idee wird als Pilotmethode bei der Auswahl der Parameter benutzt. Jedoch ist der Pilotschätzer für M in unserem Programm gegeben durch $\hat{R} := \max\left(\tilde{R}, \hat{V}\right)$, die sogenannte R-Statistik, um sicherzustellen, daß $\hat{M} \ge \hat{V}$ ist. $\hat{R}$ hängt ab von den Parametern $\{h_T, p\}$. Die optimale Bandbreite, die durch die R-Statistik für ein gegebenes p ausgewählt wird, bezeichnet man als $\hat{h}_{T,p}$. Es ist diejenige, die unter allen möglichen h_T's $\hat{R}(p)$ minimiert.

Bei Heiler und Feng[20]) wird p auch mit dem Fehlerkriterium selbst ausgewählt. In dieser Arbeit schlagen wir vor, p mit

[17]) Siehe Heiler, S./Feng, Y.: "Data-driven decomposition of seasonal time-series", Fußnote 8.
[18]) Für die genaue Beschreibung der Schätzprozedur siehe Heiler, S./Feng, Y.: "Data-driven decomposition of seasonal time series", Fußnote 8, und Feng, Y.: "Kernel and Locally Weighted Regression ...", Fußnote 11.
[19]) Siehe Rice, J.: "Bandwidth choice for nonparametric regression" in The Annals of Statistics, 12/1984, S. 1215-1230.
[20]) Siehe Heiler, S./Feng, Y.: „ Datengesteuerte Zerlegung saisonaler Zeitreihen", Fußnote 8.

Hilfe des Informationskriteriums BIC[21]) auszuwählen. BIC wurde ursprünglich zur Modellauswahl für ein parametrisches Modell vorgeschlagen. Dort ist BIC ein konsistentes Kriterium zur Modellwahl. Im vorliegenden Fall werden wir folgende Definition für BIC verwenden:

$$\mathrm{BIC}(p)=\ln\left(\hat{R}(p)\right)+\ln(n)(p+1)/n. \quad (11)$$

Der Term $\ln(n)(p+1)/n$ ist ein Strafterm für die Erhöhung der Ordnung des Polynoms. Auch BIC hängt von den beiden Parametern $\{h_T, p\}$ ab. Die optimale Auswahl ist das Paar $\left\{\hat{h}_{T,R}, \hat{p}\right\}$, das BIC minimiert. Für ein gegebenes p ist die optimale Bandbreite, die durch BIC gewählt wird, diejenige, die durch $\hat{R}(p)$ ausgewählt wird. Aber das durch BIC endgültig ausgewählte optimale Paar $\left\{\hat{h}_{T,R}, \hat{p}\right\}$ kann sich von dem durch die R-Statistik direkt gewählten unterscheiden.

Das Verfahren, $\left\{\hat{h}_{T,R}, \hat{p}\right\}$ für einen k-NN Schätzer mit festem p zu suchen, ist viel einfacher als es bei Heiler und Feng[22]) vorgeschlagen wird. Es sei $h_{max}=n$, für n ungerade oder $h_{max}=n-1$ für n gerade. Für ein gegebenes p sei $h_{min}=p+s+2$ für ungerade $p+s$ oder $h_{min}=p+s+3$ für gerade $p+s$. Gesucht wird das $\hat{h}_{T,p}$, das BIC(p) minimiert. Man wähle das Paar $\left\{\hat{h}_{T,R}, \hat{p}\right\}$ mit dem kleinsten Wert für BIC unter allen $\left\{\hat{h}_{T,p}, p\right\}$. $\left\{\hat{h}_{T,R}, \hat{p}\right\}$ ist dann die optimale Parameterwahl durch BIC.

Im folgenden werden wir untersuchen, wie man eine effektivere Bandbreite mit der DS-Regel auswählt. Dabei setzen wir voraus, daß $\hat{p}$ bereits festliegt. Für die DS-Regel benötigt man eine Pilotschätzung. Wie man bei Heiler und Feng[23]) nachlesen kann, sollte die Ordnung des Polynoms bei der Pilotglättung höher sein als bei der Hauptglättung. Daher wird $\hat{p}_P=\hat{p}+2$ bei der Pilotglättung benutzt. Die DS-Schätzung des MASE ist dann definiert durch

$$\hat{M}_D=\hat{V}+\hat{B}_D, \quad (12)$$

wobei

$$\hat{B}_D=n^{-1}\sum_{t=1}^{n}\left\{\sum_{i=1}^{n}w_i(t)\hat{m}_{p,i}-\hat{m}_{p,t}\right\}^2,$$

und wobei $\hat{m}_p$ die Pilotschätzung von m ist, die man mit $p_p=p+2$ und der durch die R-Statistik gewählten Bandbreite $\hat{h}_{T,g}$ erhalten hat. Die optimale Bandbreite $\hat{h}_{T,D}$ ist diejenige unter allen möglichen gesamten Bandbreiten, die $\hat{M}_D$ minimiert. Ein einfaches nicht-robustes datengesteuertes Verfahren ist das folgende:

1. Man schätze die Varianz mit $\hat{\sigma}_B^2$ gemäß dem Vorschlag von Heiler und Feng[24]).
2. Man wähle eine optimale Ordnung des Polynoms $\hat{p}$ gemäß BIC mit $\hat{\sigma}_B^2$ als Varianzschätzer.
3. Man wähle eine optimale Bandbreite $\hat{h}_p$ gemäß der R-Statistik mit $\hat{\sigma}_B^2$ und $p_p=\hat{p}+2$. Man berechne die Pilotschätzung $\hat{m}_p$.
4. Man wähle eine optimale gesamte Bandbreite $\hat{h}_T$ gemäß dem DS-Kriterium mit $\hat{\sigma}_B^2$, $\hat{p}$ und $\hat{m}_p$. Man berechne anschließend alle Schätzer, die man benötigt, mit $\hat{h}_T$.

Dies ist ein gegenüber dem Vorschlag von Heiler und Feng[25]) vereinfachtes Verfahren aufgrund der Verwendung des k-NN Ansatzes und einer festen Ordnung des Polynoms zu allen Beobachtungspunkten der Zeitreihe.

3 Ein robustes Verfahren mit gegebenen Parametern

Es ist gezeigt worden, daß LOWESS (Locally Weighted Scatterplot Smoothing) gute Ergebnisse bei der allgemeinen nicht parametrischen Regression liefert[26]). Cleveland und andere[27]) paßten das LOWESS Verfahren auf die Zerlegung von Zeitreihen an, wobei saisonale Schwankungen auf gegenüber unserem Verfahren unterschiedliche Art behandelt werden. In diesem Abschnitt werden wir ein robustes Verfahren zur Zerlegung von Zeitreihen vorschlagen, das auf einer weiteren Anpassung des LOWESS Verfahrens basiert. Unser Vorschlag unterscheidet sich von LOWESS in zwei Punkten: 1. Die sogenannten saisonabhängigen Mediane werden eingeführt, so daß LOWESS leicht an unser Modell angepaßt werden kann. 2. Ein stabiles Kriterium wird benutzt, das es erlaubt, die Anzahl der robusten Iterationen (NRI) datengesteuert auszuwählen. In diesem Abschnitt wird davon ausgegangen, daß die Parameter h_T und p von Hand gewählt werden. Die robuste datengesteuerte Version des BV wird im nächsten Abschnitt eingeführt. Eine ausführliche Besprechung der Eigenschaften eines solchen robusten Verfahrens findet nicht statt. Dies erfolgt an anderer Stelle.

Es sei J die maximale Anzahl der robusten Iterationen, die man durchführen möchte. Die grundlegende Idee von LOWESS ist die folgende: 1. Man passe eine nicht-robuste Schätzung $\hat{m}_0$ in der 0-ten Iteration mit Gewichtungen $k_{0,i}(t)=k_i(t)$ an, wie in Abschnitt 1.1 eingeführt; 2. Man berechne die Abweichungen $r_{j,t}=y_t-\hat{m}_{j-1}(t)$ in der j-ten ($1\le j\le J$) Iteration aus der Schätzung, die man in der (j-1)-ten Iteration erhalten hat; 3. Man weise jedem Beobachtungszeitpunkt das Robustheitsgewicht $\beta_{j,t}=B(r_{j,t}/(6\delta_j))$, $t=1, 2, ..., n$, zu, wobei δ_j den Median der

[21]) Siehe auch Schwarz, G.: "Estimating the dimension of a model" in The Annals of Statistics, 6/1978, S. 461-464, sowie Akaike, H.: "A bayesian extension of the minimum AIC procedure of autoregressive model fitting" in Biometrika, 66/1979, S. 237-242.
[22]) Siehe Heiler, S./Feng, Y.: „Datengesteuerte Zerlegung saisonaler Zeitreihen", Fußnote 8.
[23]) Siehe Fußnote 22.
[24]) Siehe Heiler, S./Feng, Y.: "Data-driven decomposition of seasonal time series", Fußnote 8.
[25]) Siehe Fußnote 8.
[26]) Siehe die Beispiele bei Cleveland, W. S., Fußnote 5, sowie Fan, J./Gijbels, I., Fußnote 6.
[27]) Siehe Cleveland, R.B./Cleveland, W.S./McRae, J.E./Terpenning, I.: "STL: A Seasonal-Trend Decomposition Procedure Based on Loess" (mit Diskussionen) in Journal of Official Statistics, Band 6, 1/1990, S. 3-73.

$|r_{j,t}|$ bezeichnet und $B(u) = (1 - u^2)^2\, 1_{[-1,1]}$ die quadratische Gewichtungsfunktion ist; 4. Man passe $\hat{m}_j$ in der j-ten Iteration an, wobei man $k_{0,i}(t)$ durch die modifizierten Gewichtungen $k_{j,i}(t) = \beta_{j,i}\, k_{0,i}(t)$ ersetzt. Diese Prozedur wird bis zur *J-ten Iteration* wiederholt.

Jedoch hängen im Falle von Zeitreihen-Zerlegungen die Abweichungen oft von der saisonalen Komponente ab. Daher wird wohl ein einheitlicher Median in diesem Zusammenhang nicht angemessen sein. Aus diesem Grund werden wir die saisonabhängigen Mediane $\delta_{j,t}$ und nicht die einheitlichen Mediane δ_j verwenden, wobei $\delta_{j,t}$ der Median der $|r_{j,t}|$ ist für alle i, für die $(i - t)/s$ ganzzahlig ist. Das bedeutet, daß die Abweichungen zuerst in s Gruppen aufgeteilt werden. Die Robustheitsgewichtungen werden dann für jede Gruppe nach der Idee von Cleveland[28]) berechnet. Die in Abschnitt 5 gegebenen Beispiele zeigen, daß der Gebrauch von saisonabhängigen Medianen gute Ergebnisse bei der Zerlegung von saisonalen Zeitreihen liefert.

Wie bei Cleveland wird die Funktion $B(u) = (1 - u^2)^2\, 1_{[-1,1]}$ benutzt, um die Robustheitsgewichtungen zu berechnen. Diese kann natürlich auch durch eine andere symmetrische nicht-negative Kernfunktion, die unimodal und symmetrisch um $u=0$ ist, ersetzt werden. Man nehme an, daß p und h_T bei allen Iterationen fest sind. Dann erfolgt die Adaptation von LOWESS an die Zerlegung von Zeitreihen folgendermaßen:

1. Bei der 0-ten Iteration dieses Verfahrens wird die Zeitreihe durch lokal gewichtete Regression zerlegt, wobei die Gewichtungen $k_{0,i}(t) = k_i(t)$ benutzt werden. Man erhält $\hat{m}_0$.

2. Bei der j-ten Iteration seien $r_{j,t} = y_t - \hat{m}_{(j-1)}(t)$, $t = 1, 2, \ldots, n$, die Residuen, die man in der $(j-1)$-ten Iteration erhalten hat. Man definiere die Robustheitsgewichtungen durch

$$\beta_{j,t} = B\left(\frac{r_{j,t}}{6\delta_{j,t}}\right), \qquad t = 1, 2, \ldots, n,$$

   wobei $\delta_{j,t}$ der saisonabhängige Median wie oben beschrieben ist.

3. Man zerlege die Zeitreihe durch lokal gewichtete Regression, wobei man $k_i(t)$ durch die modifizierten Gewichtungen $k_{j,i}(t) = \beta_{j,i}\, k_{0,i}(t)$ ersetzt.

4. Man wiederhole Schritt 2 und 3 solange, bis ein Stabilitätskriterium erfüllt ist, oder bis zu einer vorgegeben maximalen Anzahl von Iterationen.

Eine wichtige Frage dabei ist, wie viele robuste Iterationen man ausführen sollte, um zufriedenstellende Ergebnisse zu erzielen. Es ist klar, daß man mindestens zwei robuste Iterationen benötigt, da im ersten Schritt die Robustheitsgewichtungen errechnet werden aus Abweichungen, die man durch ein nicht-robustes Verfahren erhalten hat. Im folgenden werden wir ein Stabilitätskriterium vorschlagen, so daß die NRI durch die Daten bestimmt werden kann. Um die Beschreibung zu vereinfachen, setzen wir $\beta_{0,i} \equiv 1$ für alle i in der 0-ten Iteration.

Für ein gegebenes p und eine Bandbreite h_T hängen die Gewichtungen $k_{j,i}(t)$ in der j-ten Iteration nur von $\beta_{j,i}$ ab. Daher werden die Schätzungen in der j-ten Iteration nahe bei denen der $(j-1)$-ten Iteration liegen, falls $\beta_{j,i} \cong \beta_{(j-1),i}$ für alle i. Wenn man beachtet, daß $0 \le \beta_{j,i} \le 1$ für alle j und i ist, können wir die durchschnittliche absolute Differenz (AAD) zwischen $\beta_{j,i}$ und $\beta_{(j-1),i}$

$$\mathrm{AAD}_j = n^{-1} \sum_{i=1}^{n} \left|\beta_{j,i} - \beta_{(j-1),i}\right|, \quad j = 1, 2, \ldots,$$

als ein Stabilitätsmaß der robusten Schätzungen in der j-ten Iteration benutzen. Für ein gegebenes p und h_T wird AAD_j für $j \to \infty$ gegen Null konvergieren, wenn das robuste Verfahren stabil ist. Daher können wir eine kleine positive Konstante c_0 wählen und das Iterationsverfahren beenden, wenn $\mathrm{AAD}_j < c_0$ ist. Ein solcher Schätzer wird stabile robuste Schätzung genannt, oder einfach eine robuste Schätzung, falls es keine Verwechslung geben kann. Die robuste Schätzung hängt stark von c_0 ab. Wenn c_0 zu groß ist, werden die Ergebnisse nicht zufriedenstellend sein. Wenn c_0 zu klein ist, wird die Rechenzeit unnötig verlängert. In dieser Arbeit wird $c_0 = 0.0125$ benutzt.

4 Datengesteuertes, robustes Verfahren

Die in Abschnitt 2 angeführten Fehlermaße werden für einen linearen Glätter vorgeschlagen unter der Bedingung, daß die ε_t unabhängig identisch verteilte Zufallsvariablen sind.

Es versteht sich von selbst, daß die robusten lokalgewichteten Regressionsschätzer nichtlinear sind, da die Robustheitsgewichte $\beta_{j,t}$ für $j > 0$ von den Daten abhängen. In diesem Fall hängt auch das Gewichtungssystem w von den Daten ab. Aus dem im letzten Abschnitt beschriebenen robusten Verfahren kann man ersehen, daß die Abhängigkeit des Gewichtungssystems von den Daten sehr komplex ist. In dieser Ausarbeitung werden wir jedoch der Einfachheit halber die R-Statistik und das DS-Kriterium verwenden, die angemessene Methoden sind, um die Ordnung des Polynoms und die Bandbreite in einer robusten Iteration zu bestimmen. Dies ist lediglich ein Versuch, ein robustes, datengesteuertes Verfahren zur Zerlegung von Zeitreihen zu entwickeln. Es existieren auf diesem Gebiet immer noch viele offene Fragen (siehe die Schlußbemerkungen).

Die Erweiterung des Auswahlverfahrens der Bandbreite zu robusten Iterationen ist einfach, sofern man die Nichtlinearität ignoriert. Sowohl die Pilotbandbreite als auch die Hauptbandbreite müssen bei jedem iterativen Schritt neu ausgewählt werden, da die optimale Bandbreite der nächsten Iteration von der vorherigen verschieden sein kann. Daher verlangt dieses datengesteuerte, robuste Verfahren eine lange Rechenzeit. Die Schätzer der lokalen Regression hängen stark von der Bandbreite h_T ab. Neben der Stabilitätsbedingung $\mathrm{AAD}_j < c_0$ wird eine zusätzliche Stabilitätsbedingung für die Bandbreite benutzt werden. Man

[28]) Siehe Fußnote 5.

bezeichne die Bandbreite für die Hauptglättung in der j-ten Iteration als $\hat{h}_{T,j}$. Es sei $j \geq 2$. Dann wird das datengesteuerte Verfahren gestoppt, sobald $AAD_j < c_0$ und $\hat{h}_{T,j} = \hat{h}_{T,(j-1)}$. Wenn das Verfahren nicht stabil ist, wird es nach J Iterationen gestoppt werden. In diesem Fall muß die beste NRI subjektiv gewählt werden, indem man die detaillierten Resultate jeder Iteration analysiert.

Das vorgeschlagene datengesteuerte und robuste Verfahren zur Zerlegung von Zeitreihen sieht folgendermaßen aus:

1. Für $j = 0$ ermittle man $\hat{p}$, die Pilotbandbreite $\hat{h}_{p,0}$, $\hat{h}_{T,0}$ sowie $\hat{m}_0$ gemäß dem in Abschnitt 2 gegebenen nicht robusten, datengesteuerten Verfahren.
2. In der j-ten, $j > 0$, Iteration ermittle man die Robustheitsgewichte aus $\hat{m}_{(j-1)}$, welche in der $(j-1)$-ten Iteration gewonnen wurden.
3. Man wähle die optimale Pilotbandbreite $\hat{h}_{p,j}$ gemäß der R-Statistik mit dem robusten Verfahren. Man berechne den robusten Pilotschätzer $\hat{m}_{(p,j)}$.
4. Man wähle die optimale Bandbreite $\hat{h}_{T,j}$ gemäß dem DS-Kriterium mit dem robusten Verfahren und berechne den robusten Schätzer $\hat{m}_j$.
5. Für $j \geq 2$ setze $j_0 := j$ und gehe zu Schritt 6, wenn die Stabilitätsbedingungen erfüllt sind oder wenn $j_0 = J$ ist. Andernfalls setze $j := j + 1$ und gehe zurück zu Schritt 2.
6. Man berechne die anderen Schätzer mit den ausgewählten Parametern und dem robusten Verfahren.

Die ausgewählten Parameter eines solchen Verfahrens sind die Ordnung $\hat{p}$ des Polynoms und eine Folge von Bandweiten $\left\{\hat{h}_{T,0}, \hat{h}_{T,1}, \ldots \hat{h}_{T,j_0}\right\}$. Die Schätzer am Ende dieses Verfahrens hängen nicht nur von $\hat{h}_{T,j_0}$, sondern von der ganzen Folge $\left\{\hat{h}_{T,0}, \hat{h}_{T,1}, \ldots \hat{h}_{T,j_0}\right\}$ ab. Wenn wir mit dem robusten Verfahren, das wir im letzten Abschnitt vorgeschlagen haben, in jeder Iteration der j_0+1 Durchläufe mit $\hat{p}$ und der entsprechenden Bandbreite $\hat{h}_{T,j}$ durchführen, werden wir dieselben Resultate erhalten.

5 Anwendungen

In diesem Abschnitt wird das vorgeschlagene Verfahren auf die sieben Beispiele angewendet, die in den kürzlich durchgeführten Studien des Statistischen Bundesamtes[29]) verwendet wurden. Es sind dies Beobachtungen im früheren Bundesgebiet zwischen Januar 1976 und Juni 1987 für folgende Zeitreihen:

1. Arbeitslose (UNEMP),
2. PI Produzierendes Gewerbe insgesamt (PIPIN),
3. PI Herstellung von Kraftwagen und -motoren (PIAUT),
4. PI Tabakverarbeitung (PITOB),
5. PI Chemische Industrie (PICHE),
6. AI Maschinenbau (OIENG),
7. AI Bauhauptgewerbe (OIBAU),

wobei PI – Index der Nettoproduktion, AI – Index des Auftragseingangs. Hier werden $c_0 = 0.0125$ und $J = 20$ zur Zerlegung der Zeitreihen benutzt. Die geschätzten Parameter $\hat{\sigma}_B^2$, $\hat{p}$, j_0 und $\hat{h}_T = \hat{h}_{T,j_0}$ sind in der Tabelle aufgeführt. Die Bandbreiten, die in anderen Iterationen gewählt wurden, sind weggelassen worden. In der Tabelle sehen wir, daß die gewählten Parameter für diese Zeitreihen sehr verschieden sind. Das zeigt uns, daß ein Modell mit gegebenen Parametern nicht für alle Datensätze in der Praxis geeignet sein kann. Daher ist ein datengesteuertes Verfahren notwendig.

Die gewählten $\hat{p}$ und $\hat{h}_T$ hängen sowohl von der Varianz σ^2 einer Zeitreihe, als auch von der Struktur der Trend-Zyklus-Komponente ab. Je größer σ^2 (relativ) ist, desto größer ist $\hat{h}_T$. Je komplexer G ist, desto kleiner ist $\hat{h}_T$. Weiterhin hängen $\hat{p}$ und $\hat{h}_T$ voneinander ab. Je höher $\hat{p}$ ist, desto höher ist $\hat{h}_T$ und umgekehrt. Alle Beispiele, außer der Zeitreihe OIBAU, für die wir $j_0 = J$ erhalten haben, haben stabile, robuste Zerlegungsresultate ergeben. Für die Zeitreihe OIBAU schwankt die optimale Bandbreite zwischen $\hat{h}_T = 49$ und $\hat{h}_T^* = 37$. Wären $J = 19$ oder $J = 21$ angewandt worden, hätte man $\hat{h}_T^*$ als endgültiges Resultat erhalten.

Für alle Beispiele gewählte $\hat{\sigma}_B^2, \hat{p}, j_0$ und $\hat{h}_T$

Zeitreihe	$\hat{\sigma}_B^2$	$\hat{p}$	j_0	$\hat{h}_T$
UNEMP	470,79	4	10	55
PIPIN	3,767	2	7	55
PIAUT	57,20	0	4	63
PITOB	15,55	0	8	43
PICHE	2,734	2	7	37
OIENG	28,01	1	4	41
OIBAU	5,709	2	20	49

Die Zerlegungsergebnisse für die drei Zeitreihen PIAUT, PITOB und OIENG, die offenbar an einigen Stellen von Ausreißern beeinflußt werden, sind in den Schaubildern 1 bis 3 im Anschluß an diesen Beitrag dargestellt. Jedes dieser Schaubilder zeigt jeweils sowohl die Originaldaten als auch die nicht robusten Schätzungen sowie die stabilen, robusten Schätzungen von G (oben), die nicht robuste Schätzung von S (Mitte) und die stabile, robuste Schätzung von S (unten). Wie man aus diesen drei Beispielen ersehen kann, werden die Schätzungen von G und S durch das robuste Verfahren an den Stellen verbessert, an denen es Ausreißer zu geben scheint. Das Schaubild 2 zeigt, daß der Einfluß von Ausreißern (siehe die Beobachtungen um $t = 80$), welcher beim ersten Hinsehen nur schwer zu erkennen ist, durch die saisonabhängigen Mediane ebenfalls korrigiert werden kann.

Die korrigierte saisonale Komponente erscheint plausibler als die nicht robuste.[30])

[29]) Siehe Fußnote 3.

[30]) Für weitere Beispiele siehe Feng, Y., Fußnote 11.

Theoretisch ist ein ungerades p zu bevorzugen.[31]) Aber dennoch stellt sich für endliche Stichproben $\hat{m}$ mit p gerade manchmal sogar als beste Wahl heraus.

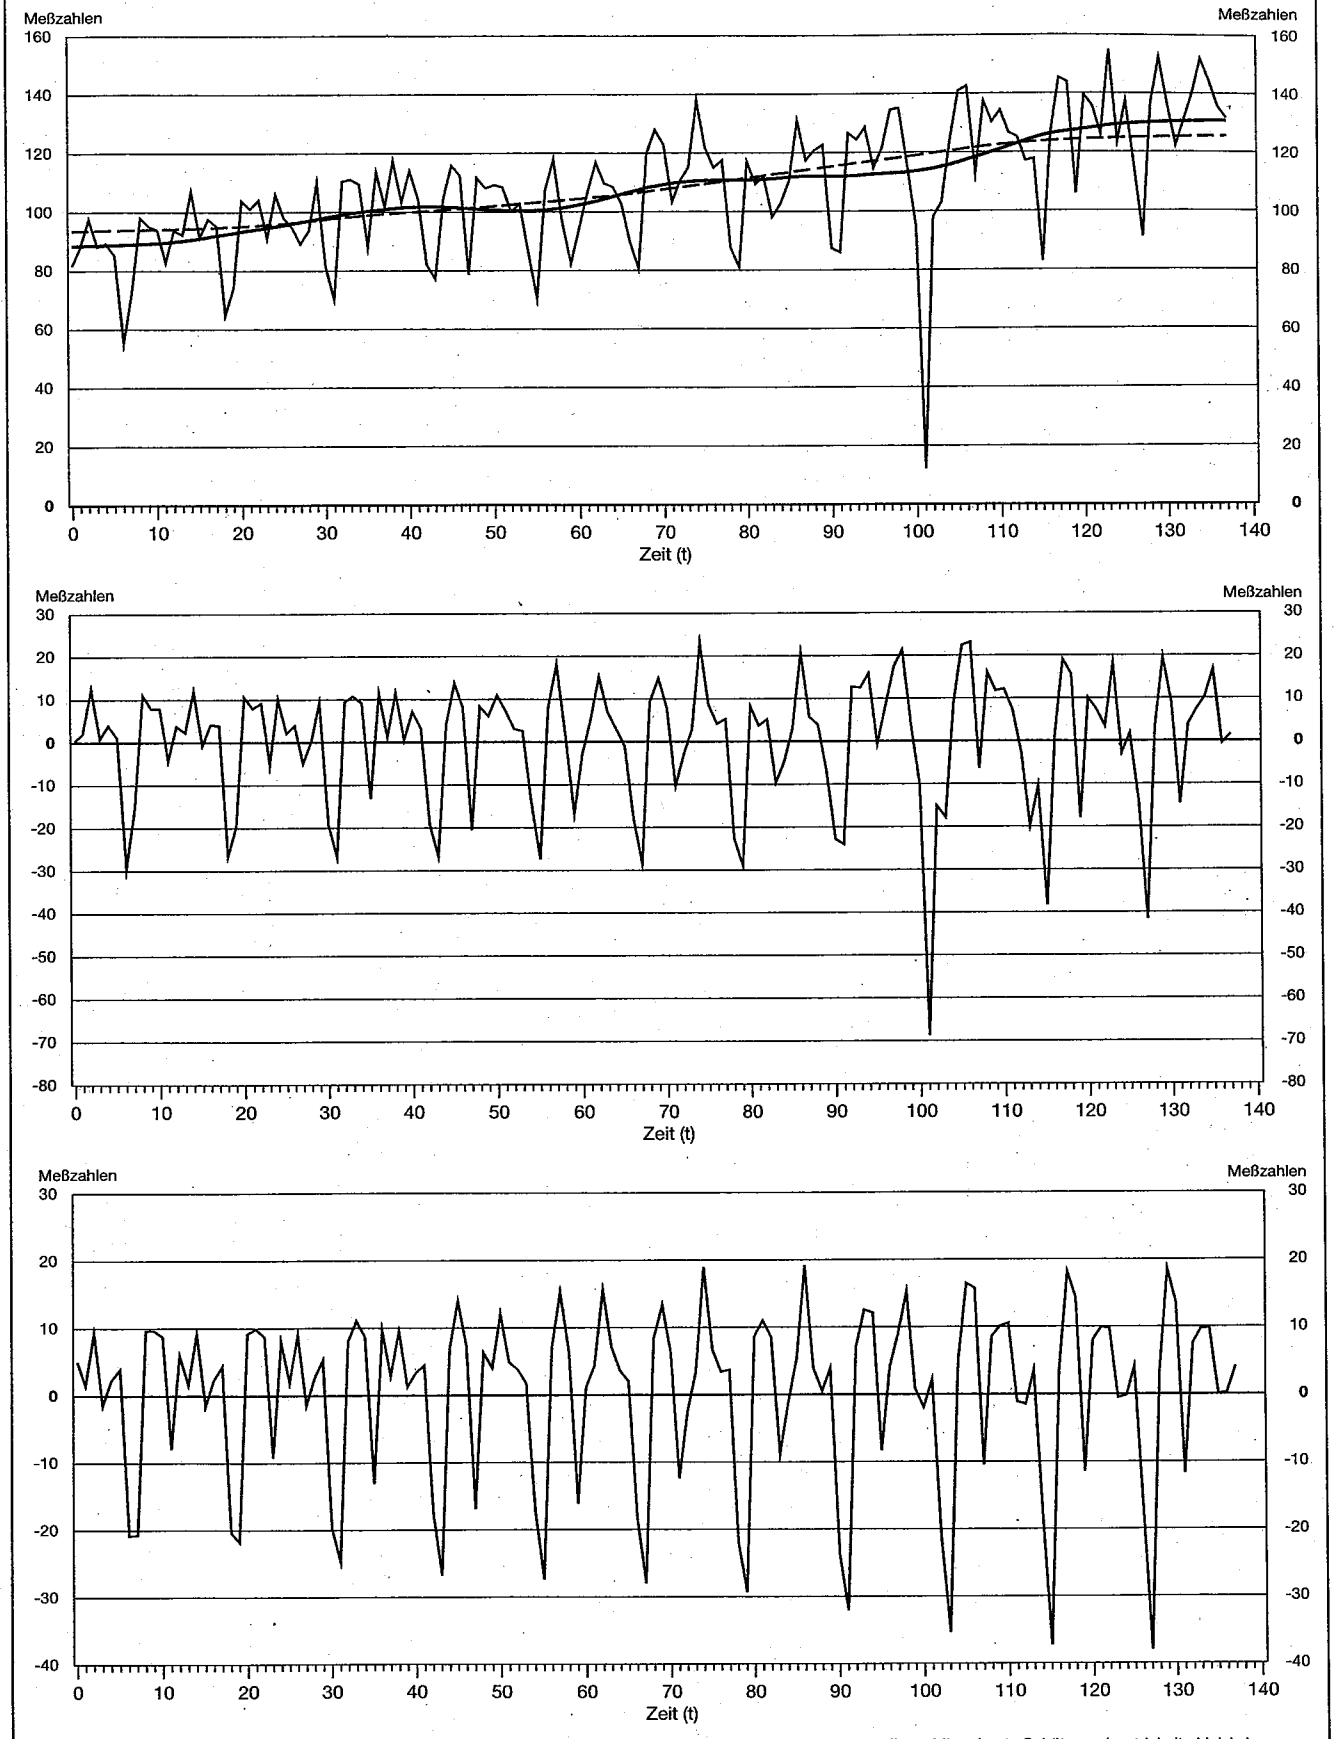
6 Schlußbemerkungen

In diesem Beitrag wird eine robuste, datengesteuerte Version des Berliner Verfahrens vorgeschlagen. Beispiele aus der Praxis zeigen, daß das vorgeschlagene Verfahren gute Ergebnisse liefert. Dennoch gibt es einige offene Fragen, die in der Zukunft noch beantwortet werden müssen. Es sollten zum Beispiel Fehlerkriterien entwickelt werden, die für die Auswahl der optimalen Parameter für das robuste Zerlegungverfahren von Zeitreihen besser geeignet sind. Der Varianzenschätzer $\hat{\sigma}_B^2$, der in diesem Beitrag verwendet wird, ist nicht robust. Ein robuster Varianzenschätzer für saisonale Zeitreihen sollte entwickelt werden. Wenn die Varianz von ε_t stark von der saisonalen Komponente abhängt, sollten sowohl das Fehlerkriterium als auch der Varianzenschätzer entsprechend dieser Tatsache angepaßt werden. Die endlichen Stichprobeneigenschaften und die asymptotischen Eigenschaften der Parameterschätzer, die durch das robuste, datengesteuerte Verfahren ausgewählt werden, sollten untersucht werden. Weiterhin ist der Fehlerprozess $\{\varepsilon_t\}$ im allgemeinen nicht unabhängig. In diesem Fall ist es schwieriger, die oben erwähnten Fragen (Probleme) zu klären. Zu bemerken ist, daß die gewählten Parameter nur optimal für die Schätzung von m sind, aber weder für $\hat{G}$ noch für $\hat{S}$ passen. Eine Entwicklung von Verfahren, bei denen optimale Parameter für $\hat{G}$ und/oder $\hat{S}$ getrennt gewählt werden können, wäre ebenfalls wünschenswert. Ein anderes Problem in der praktischen Anwendung des vorgeschlagenen neuen BV Verfahrens ist das Fehlen der Kalenderkomponente. Als Lösungsansatz könnte versucht werden, das dafür bei BV4 entwickelte Konzept auf unseren Ansatz zu übertragen.

Dr. Yuanhua Feng/Prof. Dr. Siegfried Heiler,
Universität Konstanz

[31]) Siehe Fan, J./Gijbels, I.: "Data-driven bandwidth selection in local polynomial fitting: Variable bandwidth and spatial adaptation" in Journal of the Royal Statistical Society, Series B, 57/1995, S. 371-394, und Fußnote 6.

Nicht robuste und stabile robuste Zerlegungsergebnisse für die Zeitreihe PIAUT

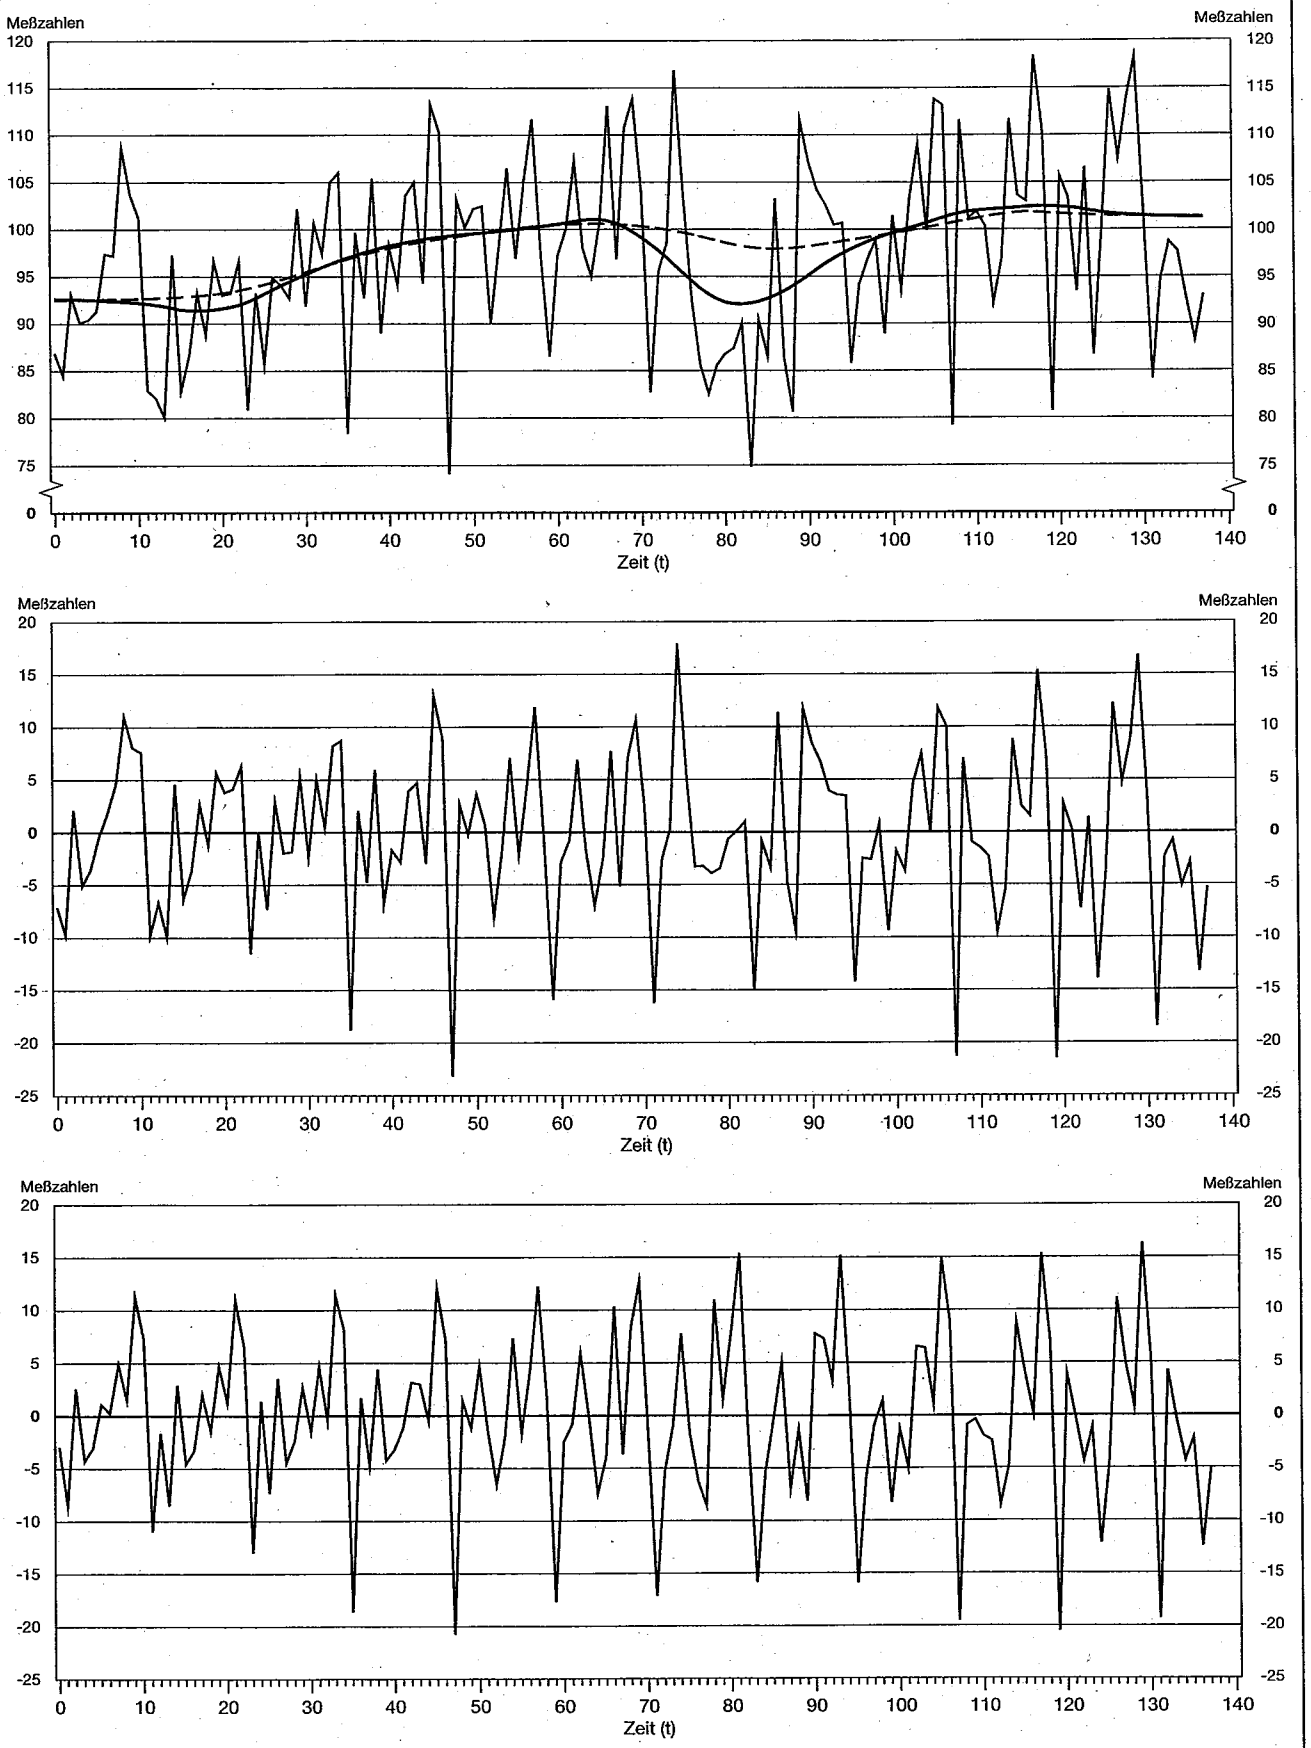


Die Schaubilder zeigen die Originaldaten der Zeitreihe, die nicht robuste Schätzung (durchgezogene Linie) sowie die stabile robuste Schätzung (gestrichelte Linie) der Trend-Zyklus-Komponente G (oben), die nicht robuste Schätzung der Saisonkomponente S (Mitte) und die stabile robuste Schätzung der Saisonkomponente S (unten).

Statistisches Bundesamt 2000 - 01 - 0615

Schaubild 2

Nicht robuste und stabile robuste Zerlegungsergebnisse für die Zeitreihe PITOB

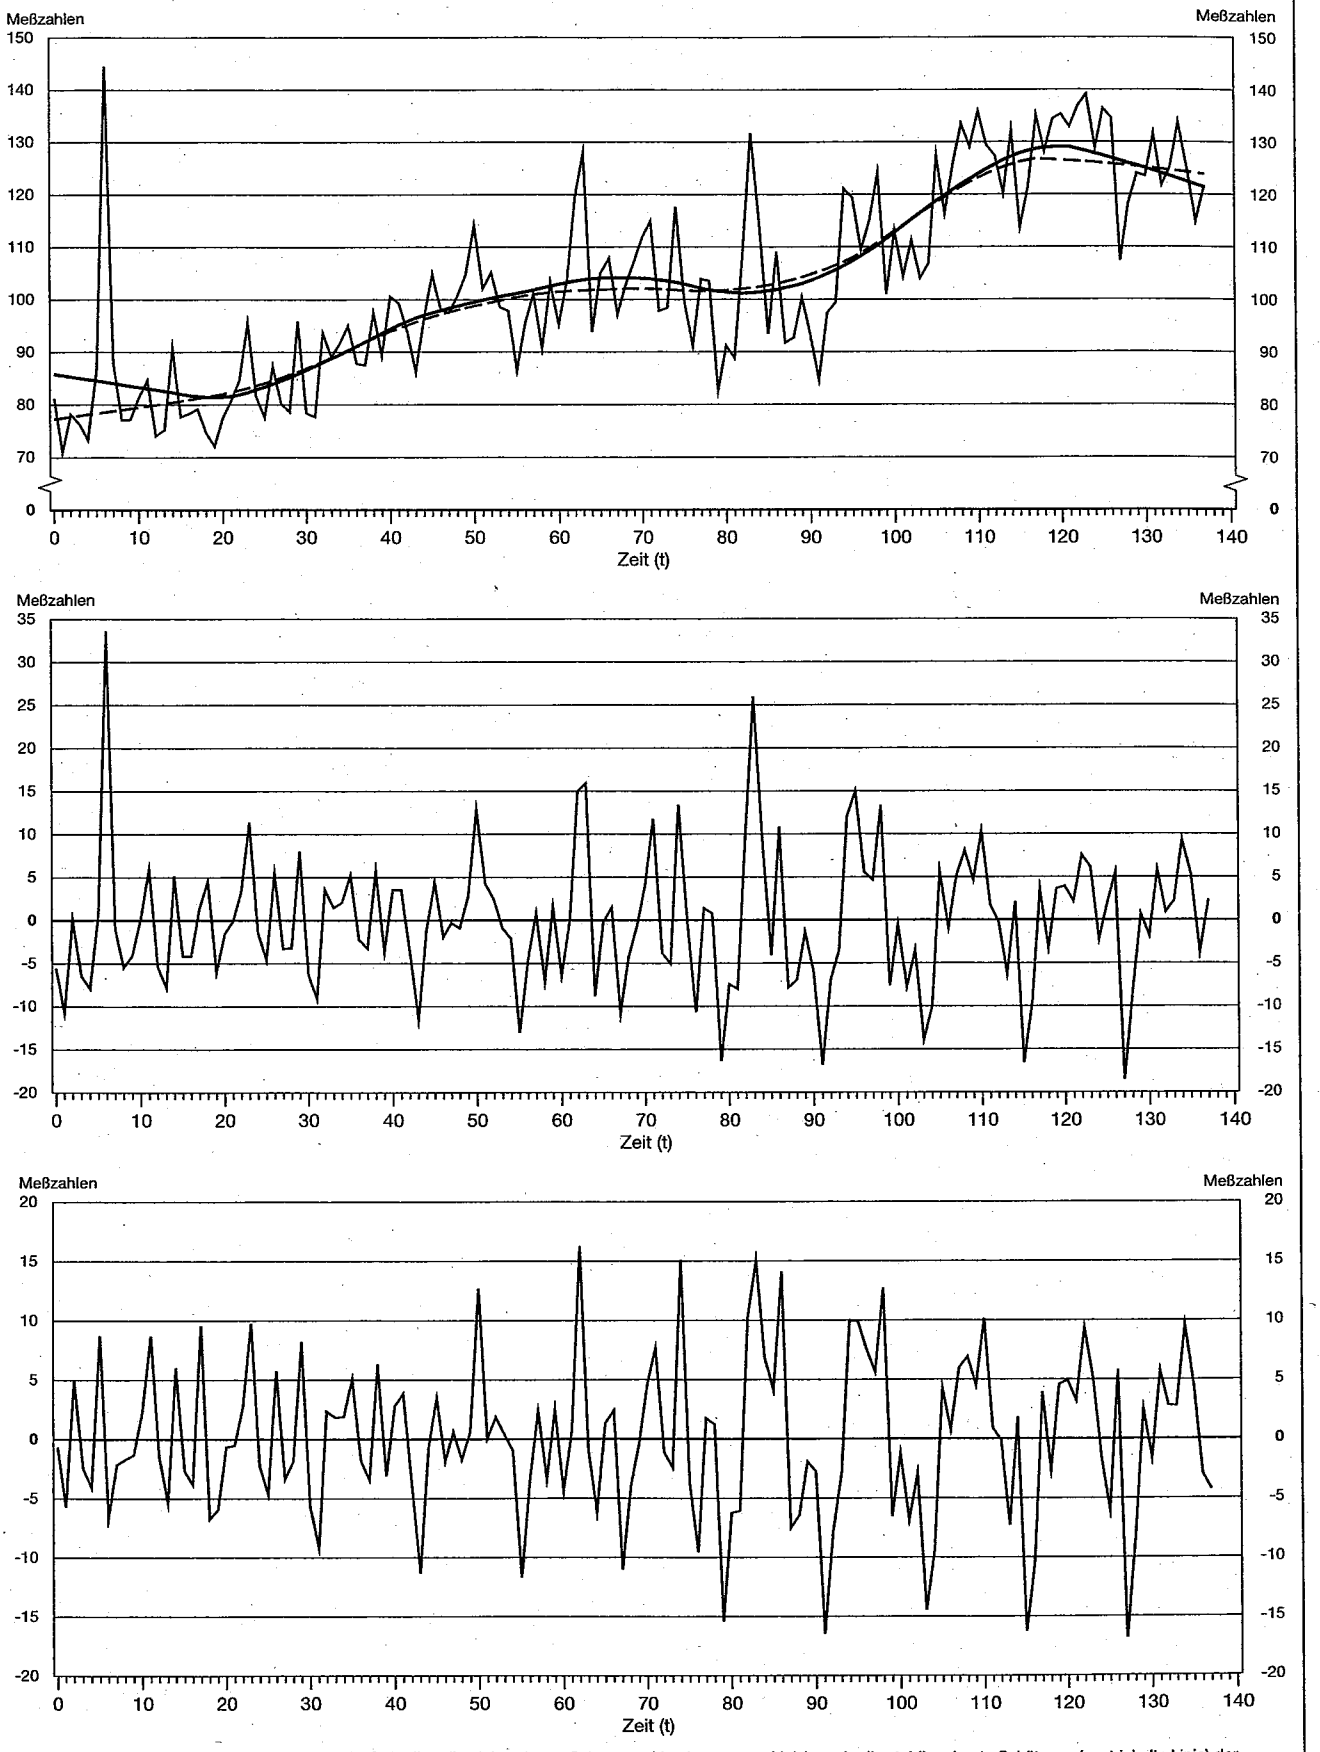


Die Schaubilder zeigen die Originaldaten der Zeitreihe, die nicht robuste Schätzung (durchgezogene Linie) sowie die stabile robuste Schätzung (gestrichelte Linie) der Trend-Zyklus-Komponente G (oben), die nicht robuste Schätzung der Saisonkomponente S (Mitte) und die stabile robuste Schätzung der Saisonkomponente S (unten).

Statistisches Bundesamt 2000 - 01 - 0616

Schaubild 3

Nicht robuste und stabile robuste Zerlegungsergebnisse für die Zeitreihe OIENG



Die Schaubilder zeigen die Originaldaten der Zeitreihe, die nicht robuste Schätzung (durchgezogene Linie) sowie die stabile robuste Schätzung (gestrichelte Linie) der Trend-Zyklus-Komponente G (oben), die nicht robuste Schätzung der Saisonkomponente S (Mitte) und die stabile robuste Schätzung der Saisonkomponente S (unten).

Statistisches Bundesamt 2000 - 01 - 0617